

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
NÚCLEO DE EDUCAÇÃO A DISTÂNCIA
Pós-graduação *Lato Sensu* em Ciência de Dados e Big Data

Bruno Vieira Cardoso

Modelo preditivo de preço de commodities

Belo Horizonte
2021

Bruno Vieira Cardoso

Modelo preditivo de preço de commodities

Trabalho de Conclusão de Curso apresentado
ao Curso de Especialização em Ciência de
Dados e Big Data como requisito parcial à
obtenção do título de especialista.

Belo Horizonte

2021

SUMÁRIO

1. Introdução.....	4
1.1. Contextualização	4
1.2. O problema proposto	5
2. Coleta de Dados	5
3. Processamento/Tratamento de Dados	7
4. Análise e Exploração dos Dados	12
5. Criação de Modelos de Machine Learning	17
6. Apresentação dos Resultados	24
7. Links	31
REFERÊNCIAS.....	32
APÊNDICE	34

1. Introdução

1.1. Contextualização

O mercado financeiro, em regra, antecipa os movimentos econômicos através da análise das mais diversas variáveis – econômicas, políticas, sociais, ambientais, regulatórias etc. Um exemplo seria uma decisão política implementada hoje, cujos reflexos na economia real só serão percebidos daqui a alguns meses, já tem seus efeitos reconhecidos no mesmo dia e dias posteriores nos preços dos ativos e índices da B3 – bolsa de valores oficial do Brasil.

Portanto, é um ambiente com bastante volatilidade em razão dos diversos fatores que influenciam o andamento da economia e com reflexos imediatos no preço dos ativos e valores dos índices.

Essa característica do mercado financeiro, de antecipar e fazer projeções para o futuro da economia real, certamente é uma vantagem para o planejamento de investidores, empresas e governos. Realizar projeções com base nessas antecipações, podem evitar desastres econômicos e permitir mais geração de riqueza para o país como um todo.

É possível, a título de exemplo, identificar a tendência dos valores de um índice específico de um setor e adotarem-se políticas de estímulo ou retração antes que o impacto ocorra na economia real. O mesmo pode ser dito em relação aos preços das commodities, como é o caso do petróleo, objeto de estudo deste trabalho.

Desta forma, essa dinâmica presente no mercado financeiro, de ajustar quase que imediatamente os preços dos ativos e os valores dos índices com base em eventos que, na maioria das vezes, só surtirão efeitos na economia real bem depois, é, sem dúvida, uma ferramenta que pode servir como orientadora para tomadas de decisão mais precisas e certeiras, além de representar também uma vantagem temporal significativa em relação à adoção de medidas. Essa agilidade e sensibilidade do mercado financeiro, quando projetada de forma preditiva, pode demonstrar se a economia como um todo ou de um setor está evoluindo ou não na direção adequada, permitindo a adoção de medidas que irão estimular ou inibir a valoração de ativos ou impacto dos eventos previstos a partir dessa análise.

1.2. O problema proposto

O presente estudo busca apresentar modelos preditivos em relação ao comportamento do preço do petróleo, além de suas análises exploratória. Desta forma, requer a extração das séries temporais de valores e preços de fechamento desta commodity para auxiliar o governo na definição de políticas fiscais que contenham ou estimulem a variação de seu preço ou os seus impactos econômicos na economia real.

Para tanto, foi escolhido os dois principais petróleos do mundo: o Brent e o WTI. Desta forma, consta do estudo:

- A análise descritiva dos dois ativos em questão;
- Verificar a correlação entre todos eles;
- Criação de modelo preditivo para o petróleo Brent através da biblioteca ARIMA e Facebook Prophet.

Os dados extraídos são dos anos de 2010 a 2019, sendo que as informações de 2010 até 2016 foram utilizadas como base de treinamento e os demais anos como teste.

2. Coleta de Dados

Constam no trabalho a análise de dois *datasets*, conforme segue:

- Dataset1: petróleo Brent (diário a partir de 01/01/2010 até 31/12/2019)
- Dataset2: petróleo WTI (diário a partir de 01/01/2010 até 31/12/2019)

Os dados foram coletados, respectivamente, no site Investing.com, através dos seguintes links:

- <https://br.investing.com/commodities/brent-oil-historical-data>
- <https://br.investing.com/commodities/crude-oil-historical-data>

Nome da coluna/campo	Descrição	Tipo
Data	Data de negociação do ativo	Pandas(index)
Último	Valor de fechamento do ativo	Pandas
Abertura	Valor de abertura do ativo	Pandas
Máxima	Valor máximo atingido pelo ativo	Pandas
Mínima	Valor mínimo atingido pelo ativo	Pandas
Vol.	Volume financeiro negociado pelo ativo	Pandas
Var%	Variação percentual do ativo em relação ao dia anterior de negociação	Pandas

3. Processamento/Tratamento de Dados

Os *datasets* 1 e 2 apresentam 2581 e 2591 linhas, respectivamente, e 7 colunas.

In [7]: `brent`

Out[7]:

	Data	Último	Abertura	Máxima	Mínima	Vol.	Var%
0	31.12.2019	66.00	66.65	66.93	65.63	171,01K	-3,57%
1	30.12.2019	68.44	68.20	68.99	68.16	29,42K	0,41%
2	27.12.2019	68.16	67.91	68.33	67.57	112,22K	0,35%
3	26.12.2019	67.92	67.27	67.99	67.22	69,82K	1,07%
4	24.12.2019	67.20	66.44	67.26	66.36	104,94K	1,22%
...
2576	08.01.2010	81.37	81.51	82.05	80.59	157,49K	-0,17%
2577	07.01.2010	81.51	82.00	82.05	81.05	131,28K	-0,46%
2578	06.01.2010	81.89	80.38	82.21	79.77	157,87K	1,61%
2579	05.01.2010	80.59	80.29	80.84	79.75	131,75K	0,59%
2580	04.01.2010	80.12	78.49	80.48	78.34	122,64K	2,81%

2581 rows x 7 columns

Com o carregamento dos *datasets* para o notebook, ficou evidente a necessidade de tratamento dos dados presentes.

O primeiro passo foi estabelecer as datas no formato adequado e defini-las como *index* dos *datasets*.

```
brent['Data'] = pd.to_datetime(brent['Data'], format='%d.%m.%Y')
wti['Data'] = pd.to_datetime(wti['Data'], format='%d.%m.%Y')

brent.index = pd.to_datetime(brent.Data, format='%d.%m.%Y')
wti.index = pd.to_datetime(wti.Data, format='%d.%m.%Y')

brent.index.to_period('D')
wti.index.to_period('D')
```

O segundo passo foi corrigir as formas como os valores estavam expressos em relação às vírgulas e pontos. Além disso, o campo volume dos *datasets*, apresentavam, além dos valores, letras que representavam valores ('K' para milhares, 'M' para milhões e 'B' para bilhões). Desta forma, para ambos *datasets* houve o tratamento especial em relação a essas letras na coluna "Vol.", para

transformá-las em apenas números. A título de exemplo, abaixo está exposto o código utilizado no *dataset* de Brent.

```
brent["Abertura"] = brent["Abertura"].astype(str)
brent["Último"] = brent["Último"].astype(str)
brent["Máxima"] = brent["Máxima"].astype(str)
brent["Mínima"] = brent["Mínima"].astype(str)
brent["Var%"] = brent["Var%"].astype(str)
brent["Vol."] = brent["Vol."].astype(str)

brent["Abertura"] = pd.Series(brent["Abertura"]).str.replace(',', '.', regex=True)
brent["Último"] = pd.Series(brent["Último"]).str.replace(',', '.', regex=True)
brent["Máxima"] = pd.Series(brent["Máxima"]).str.replace(',', '.', regex=True)
brent["Mínima"] = pd.Series(brent["Mínima"]).str.replace(',', '.', regex=True)
brent["Var%"] = pd.Series(brent["Var%"]).str.replace(',', '.', regex=True)
brent["Var%"] = pd.Series(brent["Var%"]).str.replace('%', '', regex=True)
brent["Vol."] = pd.Series(brent["Vol."]).str.replace('-', '', regex=True)
brent["Vol."] = pd.Series(brent["Vol."]).str.replace('.', '', regex=True)
brent["Vol."] = pd.Series(brent["Vol."]).str.replace('M', "000000", regex=True)
brent["Vol."] = pd.Series(brent["Vol."]).str.replace('K', "000", regex=True)
brent["Vol."] = pd.Series(brent["Vol."]).str.replace('B', "000000000", regex=True)

brent["Abertura"] = pd.to_numeric(brent["Abertura"])
brent["Último"] = pd.to_numeric(brent["Último"])
brent["Máxima"] = pd.to_numeric(brent["Máxima"])
brent["Mínima"] = pd.to_numeric(brent["Mínima"])
brent["Var%"] = pd.to_numeric(brent["Var%"])
brent["Vol."] = pd.to_numeric(brent["Vol."])
```

Identificou-se, em seguida, que havia dados ausentes.

```
brent.isnull().sum()
```

```
Data      0
Último    0
Abertura  0
Máxima    0
Mínima    0
Vol.      1
Var%      0
dtype: int64
```

```
wti.isnull().sum()
```

```
Data      0
Último    0
Abertura  0
Máxima    0
Mínima    0
Vol.     74
Var%      0
dtype: int64
```

Portanto, utilizou-se as médias móveis de 5 períodos para preencher as colunas de valores que possuíam dados ausentes, conforme tela abaixo apresentando os códigos aplicados no *dataset* de Brent.


```

brent_medianaMA = brent["Máxima"].rolling(5).mean().shift(-5).round(0)
brent_medianaMI = brent["Mínima"].rolling(5).mean().shift(-5).round(0)
brent_medianaAB = brent["Abertura"].rolling(5).mean().shift(-5).round(0)
brent_medianaUL = brent["Último"].rolling(5).mean().shift(-5).round(0)
brent_medianaVOL = brent["Vol."].rolling(5).mean().shift(-5).round(0)
brent["Máxima"].fillna(brent_medianaMA, inplace=True)
brent["Mínima"].fillna(brent_medianaMI, inplace=True)
brent["Abertura"].fillna(brent_medianaAB, inplace=True)
brent["Último"].fillna(brent_medianaUL, inplace=True)
brent["Vol."].fillna(brent_medianaVOL, inplace=True)

```

Por fim, juntou-se os *datasets* já tratados em um só, conforme segue.

```

brent.rename(columns= {'Data': 'data'}, inplace=True)
wti.rename(columns= {'Data': 'data'}, inplace=True)

bw = pd.merge(brent,wti,how='inner', on=['data'],suffixes=('_B', '_W'))

```

Assim, alterou-se o nome da coluna “Data” para “data”, para evitar conflito entre ela e o index, e criou-se o *dataset* “bw”.

bw

	data	Último_B	Abertura_B	Máxima_B	Mínima_B	Vol._B	Var%_B	Último_W	Abertura_W	Máxima_W	Mínima_W	Vol._W	Var%_W
0	2019-12-31	66.00	66.65	66.93	65.63	17101000.0	-3.57	61.06	61.68	61.88	60.63	49454000.0	-1.01
1	2019-12-30	68.44	68.20	68.99	68.16	2942000.0	0.41	61.68	61.71	62.34	61.09	42715000.0	-0.06
2	2019-12-27	68.16	67.91	68.33	67.57	11222000.0	0.35	61.72	61.73	61.97	61.24	35190000.0	0.06
3	2019-12-26	67.92	67.27	67.99	67.22	6982000.0	1.07	61.68	61.20	61.83	61.06	26509000.0	0.80
4	2019-12-24	67.20	66.44	67.26	66.36	10494000.0	1.22	61.11	60.63	61.16	60.47	20454000.0	0.97
...
2555	2010-01-08	81.37	81.51	82.05	80.59	15749000.0	-0.17	82.75	82.65	83.47	81.80	31038000.0	0.11
2556	2010-01-07	81.51	82.00	82.05	81.05	13128000.0	-0.46	82.66	83.20	83.36	82.26	24663000.0	-0.63
2557	2010-01-06	81.89	80.38	82.21	79.77	15787000.0	1.61	83.18	81.43	83.52	80.85	37006000.0	1.72
2558	2010-01-05	80.59	80.29	80.84	79.75	13175000.0	0.59	81.77	81.63	82.00	80.95	25889000.0	0.32
2559	2010-01-04	80.12	78.49	80.48	78.34	12264000.0	2.81	81.51	79.63	81.79	79.63	26354000.0	2.71

2560 rows x 13 columns

O campo ‘data’ foi estabelecido como index do *dataset* ‘bw’.

```
bw.index = pd.to_datetime(bw.data, format='%d.%m.%Y')
```

```
bw
```

	data	Último_B	Abertura_B	Máxima_B	Mínima_B	Vol._B	Var%_B	Último_W	Abertura_W	Máxima_W	Mínima_W	Vol._W	Var%_W	
	data													
	2019-12-31	2019-12-31	66.00	66.65	66.93	65.63	17101000.0	-3.57	61.06	61.68	61.88	60.63	49454000.0	-1.01
	2019-12-30	2019-12-30	68.44	68.20	68.99	68.16	2942000.0	0.41	61.68	61.71	62.34	61.09	42715000.0	-0.06
	2019-12-27	2019-12-27	68.16	67.91	68.33	67.57	11222000.0	0.35	61.72	61.73	61.97	61.24	35190000.0	0.06
	2019-12-26	2019-12-26	67.92	67.27	67.99	67.22	6982000.0	1.07	61.68	61.20	61.83	61.06	26509000.0	0.80
	2019-12-24	2019-12-24	67.20	66.44	67.26	66.36	10494000.0	1.22	61.11	60.63	61.16	60.47	20454000.0	0.97
	
	2010-01-08	2010-01-08	81.37	81.51	82.05	80.59	15749000.0	-0.17	82.75	82.65	83.47	81.80	31038000.0	0.11
	2010-01-07	2010-01-07	81.51	82.00	82.05	81.05	13128000.0	-0.46	82.66	83.20	83.36	82.26	24663000.0	-0.63
	2010-01-06	2010-01-06	81.89	80.38	82.21	79.77	15787000.0	1.61	83.18	81.43	83.52	80.85	37006000.0	1.72
	2010-01-05	2010-01-05	80.59	80.29	80.84	79.75	13175000.0	0.59	81.77	81.63	82.00	80.95	25889000.0	0.32
	2010-01-04	2010-01-04	80.12	78.49	80.48	78.34	12264000.0	2.81	81.51	79.63	81.79	79.63	26354000.0	2.71

2560 rows x 13 columns

Feita a junção, separou-se novamente os *datasets*, agora em Brent1 e Wti1, contendo o mesmo número de linha e datas em comum, conforme exemplo.

```
brent1 = pd.DataFrame(columns={"data", "Abertura_B", "Máxima_B", "Mínima_B", "Último_B", "Vol._B"}).copy()
brent1["data"] = bw["data"]
brent1["Abertura_B"] = bw["Abertura_B"]
brent1["Máxima_B"] = bw["Máxima_B"]
brent1["Mínima_B"] = bw["Mínima_B"]
brent1["Último_B"] = bw["Último_B"]
brent1["Vol._B"] = bw["Vol._B"]
```

```
brent1
```

	Último_B	Vol._B	data	Mínima_B	Abertura_B	Máxima_B
data						
2019-12-31	66.00	17101000.0	2019-12-31	65.63	66.65	66.93
2019-12-30	68.44	2942000.0	2019-12-30	68.16	68.20	68.99
2019-12-27	68.16	11222000.0	2019-12-27	67.57	67.91	68.33
2019-12-26	67.92	6982000.0	2019-12-26	67.22	67.27	67.99
2019-12-24	67.20	10494000.0	2019-12-24	66.36	66.44	67.26
...
2010-01-08	81.37	15749000.0	2010-01-08	80.59	81.51	82.05
2010-01-07	81.51	13128000.0	2010-01-07	81.05	82.00	82.05
2010-01-06	81.89	15787000.0	2010-01-06	79.77	80.38	82.21
2010-01-05	80.59	13175000.0	2010-01-05	79.75	80.29	80.84
2010-01-04	80.12	12264000.0	2010-01-04	78.34	78.49	80.48

2560 rows x 6 columns

Em seguida, foi realizada a segregação dos dados de treino, de 2010 a 2016, e teste, de 2017 a 2019.

```
filtroB = brent1['Data']<= "2016-12-31"  
train_B = brent1[filtroB]  
  
filtroW = wti1['Data']<= "2016-12-31"  
train_W = wti1[filtroW]  
  
filtroBteste = brent1['Data']> "2016-12-31"  
teste_B = brent1[filtroBteste]  
  
filtroWteste = wti1['Data']> "2016-12-31"  
teste_W = wti1[filtroWteste]
```

4. Análise e Exploração dos Dados

Inicialmente, os dados utilizados na análise e exploração de dados, foram os dados de treino apenas. Assim, foram apuradas as correlações entre os *datasets*, mais especificamente os preços de cada um deles através da coluna 'Último' – que faz referência ao preço de fechamento diário.

A correlação de preço de ambos foi considerada muito forte e diretamente proporcional, já que seu valor foi de 0,97.

```
train_B["Último_B"].corr(train_W["Último_W"])  
0.9745391323161525
```

Abaixo o gráfico de correlação.




Gráfico de correlação: Brent x WTI

A correlação entre os preços presentes nos dois *datasets* também é possível ser verificada pelo gráfico abaixo, que apresenta a oscilação de preço diária de ambos os ativos.




Gráfico de preços – Brent x WTI

Nota-se que ao longo dos anos o Brent possui valor superior ao WTI e que ambos, em regra, movimentam na mesma direção e proporção diariamente.

Posteriormente, iniciou-se a análise exploratória dos *datasets*. Iniciou-se pela descrição estatística dos dados.

```
train_B.describe()
```

	Último_B	Vol._B	Mínima_B	Abertura_B	Máxima_B
count	1787.000000	1.787000e+03	1787.000000	1787.000000	1787.000000
mean	86.978215	1.943510e+07	85.900235	86.967857	87.963212
std	27.329470	7.398364e+06	27.210115	27.278378	27.340258
min	27.880000	1.152000e+06	27.100000	27.990000	28.750000
25%	59.230000	1.535850e+07	58.375000	59.580000	60.560000
50%	99.650000	1.950300e+07	97.920000	99.540000	100.620000
75%	109.885000	2.356550e+07	108.900000	109.760000	110.800000
max	126.650000	4.638100e+07	125.000000	126.580000	128.400000

Descrição estatística - Brent

```
train_W.describe()
```

	Mínima_W	Máxima_W	Último_W	Vol._W	Abertura_W
count	1787.000000	1787.000000	1787.000000	1.787000e+03	1787.000000
mean	77.664057	79.767185	78.753643	3.200921e+07	78.779239
std	22.891260	22.972323	22.978843	1.581953e+07	22.954251
min	26.050000	27.480000	26.210000	2.210000e+06	27.300000
25%	52.055000	54.005000	53.000000	2.244200e+07	53.045000
50%	85.550000	87.770000	86.670000	2.941880e+07	86.570000
75%	96.260000	98.065000	97.330000	3.937150e+07	97.310000
max	112.250000	114.830000	113.930000	1.310000e+08	113.890000

Descrição estatística - WTI

Após verificação, foi constatada a inexistência de dados ausentes. Desta forma, foi plotado o gráfico de *candles*, contendo elementos sobre a abertura, fechamento, máxima e mínima do ativo.



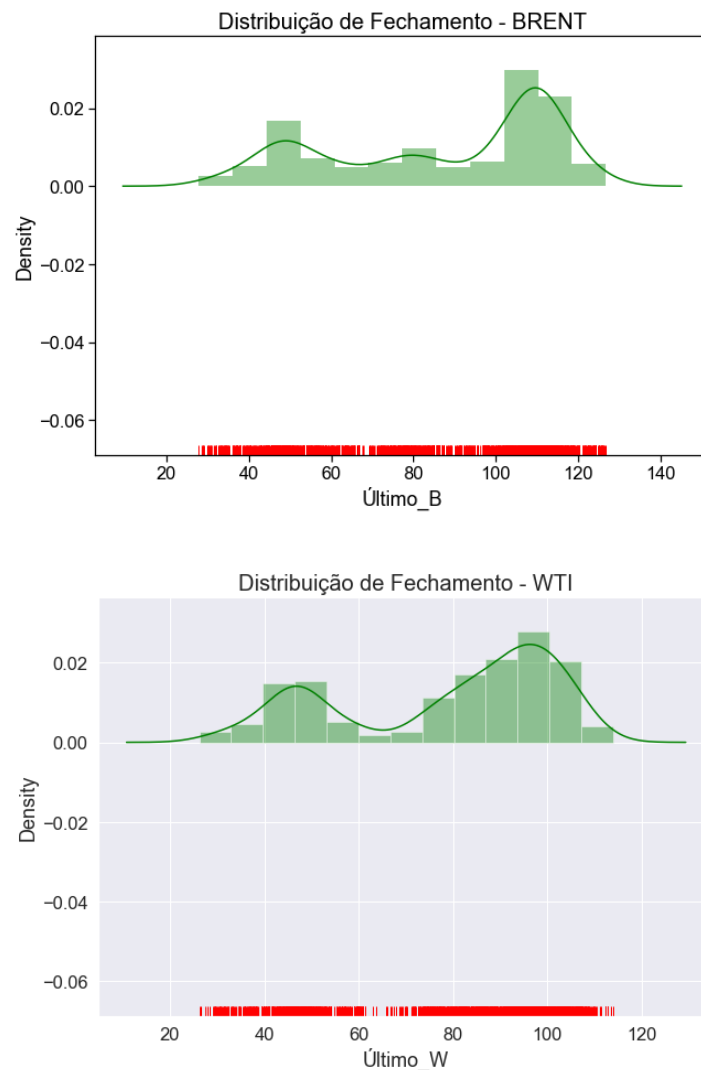
Gráfico de candles - Brent



Gráfico de candles - WTI

É possível perceber que, em ambos os ativos, o preço subiu de 2010 até meados de 2011. Após isso, permaneceu lateral até meados de 2014, quando sofreu uma acentuada correção para baixo até início de 2016.

Em seguida, foi plotado o gráfico contendo a distribuição de frequência de preços do ativo.



Ambos os ativos apresentam dois picos de concentração de preço: 45 e 105 para a distribuição do Brent e 50 e 95 para o WTI.

O código a seguir é referente ao gráfico de preço e volume, portanto, contendo dois eixos y.



Gráfico Preço x Volume - Brent




Gráfico Preço x Volume - WTI

O volume do Brent apresenta-se regular ao longo dos anos, com picos esporádicos, independente das oscilações de seu preço. Já o volume do WTI, apresenta-se da mesma forma somente até 2015, quando inicia uma tendência de alta em seu volume, indiretamente proporcional à queda do preço do ativo. Portanto, em princípio, a queda do preço do Brent não alterou seu volume de negociação. Já em relação ao WTI, a mesma queda resultou em aumento de volume de operações do ativo.

5. Criação de Modelos de Machine Learning

A seguir serão apresentados os modelos preditivos do ativo financeiro petróleo Brent, desenvolvido em linguagem Python, nas seguintes bibliotecas: Facebook Prophet, Sktime e Arima.

5.1. Facebook Prophet

Inicialmente, definiu-se as datas de treinamento e teste. Após, duplicou-se o *dataset* 'brent1' através da criação do 'brent2'.

```
train_start_date = '2010-01-01'
train_end_date = '2016-12-31'

test_start_date = '2017-01-01'
test_end_date = '2019-12-31'

brent2 = brent1
```

Aplicou-se a definição temporal de tempo aos *datasets* criando 'train_B2', para treinamento, e 'teste_b2' para o teste. Por fim, excluiu-se todas as colunas, deixando apenas a referente às datas (Data) e preço de fechamento (Último).

```
filtroB2 = brent2['Data'] <= train_end_date
train_B2 = brent2[filtroB2]

filtroB2teste = brent2['Data'] > train_end_date
teste_B2 = brent2[filtroB2teste]

train_B2.drop(columns=["Máxima_B", "Abertura_B", "Mínima_B", "Vol._B"])
```

A mesma exclusão foi aplicada em 'teste_B2'. Por fim, 'train_B2' apresentou 1787 linhas e 'teste_B2' apresentou 773 linhas.

O Prophet exige a mudança do nome das colunas no formato a seguir:

```
train_B2_FP = pd.DataFrame({"ds": train_B2['Data'], "y": train_B2['Último_B']})
train_B2_FP.reset_index(drop=True, inplace=True)
train_B2_FP
```

A mesma alteração foi aplicada em 'teste_B2'.

A seguir foi criado o código do modelo, definindo um valor baixo (0,5) para o parâmetro que modula a flexibilidade da seleção automática de ponto de mudança (Changepoint_prior_scale), portanto, garantindo poucos pontos de mudança; definindo o intervalo de incertezas para a previsão em 0,95; e atribuindo 'False' ao ajuste de sazonalidade diária (Daily_seasonality).

```
prophet_model = Prophet(changepoint_prior_scale=0.05, interval_width=0.95, daily_seasonality=False)
prophet_model.fit(train_B2_FP)
```

Abaixo o erro encontrado:

```
MAE: 17.145523353934433
MSE: 373.3109475977907
RMSE: 19.321256366959958
```

5.2. SKTIME

Inicialmente, foi instalado o pacote SKTIME.

```
pip install sktime
```

Em seguida, instalou-se algumas bibliotecas específicas do pacote.

```

from sktime.forecasting.arima import ARIMA, AutoARIMA
from sktime.forecasting.base import ForecastingHorizon
from sktime.forecasting.compose import (
    EnsembleForecaster,
    ReducedRegressionForecaster,
    TransformedTargetForecaster,
)
from sktime.forecasting.exp_smoothing import ExponentialSmoothing
from sktime.forecasting.model_selection import (
    ForecastingGridSearchCV,
    SlidingWindowSplitter,
    temporal_train_test_split,
)
from sktime.forecasting.naive import NaiveForecaster
from sktime.forecasting.theta import ThetaForecaster
from sktime.forecasting.trend import PolynomialTrendForecaster
from sktime.performance_metrics.forecasting import sMAPE, smape_loss
from sktime.transformations.series.detrend import Deseasonalizer, Detrender
from sktime.utils.plotting import plot_series

%matplotlib inline

```

Foram criados novos *datasets* com base nos anteriores, de 'B2' para 'B3'. Estabeleceu-se 'y_train' como base de treino e 'y_test' como teste.

```

train_B3=train_B2
teste_B3=teste_B2

y_train=train_B3
y_test=teste_B3

```

Tal qual com os procedimentos já adotados anteriormente, foram excluídas as colunas, exceto 'Data' e 'Último'. Por fim, eles foram ordenados pela data, que se tornou index do *dataset*.

Foi definida a frequência diária do *dataset*.


```

y=y.resample('d').mean()

```

A partir disso, ele incluiu no *dataset* todas as datas e atribuiu valor NaN para os dados ausentes. Desta forma, essas linhas foram preenchidas com a média móvel de 5 períodos.

Em seguida, foi plotado um gráfico para observar a série, com dados de treinamento e teste.



Por fim, foi definido o período a ser predito.

```
fh = ForecastingHorizon(y_test.index, is_relative=False)
fh
```

5.3. ARIMA

Inicialmente, foi instalado a biblioteca Autoarima.

```
%matplotlib inline
from matplotlib.pylab import rcParams
rcParams['figure.figsize']=15,6

from pmdarima.arima import auto_arima
```

Foi criado um novo *dataset* de treinamento ('Z') a partir de um anterior ('y_trainl').

```
z= y_trainI.copy()
z=z.drop(columns=["Data"])
z
```

Último_B	
data	
2010-01-04	80.12
2010-01-05	80.59
2010-01-06	81.89
2010-01-07	81.51
2010-01-08	81.37
...	...
2016-12-23	55.16
2016-12-27	56.09
2016-12-28	56.22
2016-12-29	56.14
2016-12-30	56.82

1787 rows × 1 columns

O código abaixo foi aplicado para processar o Autoarima.

```
stepwise_model=auto_arima(z, start_p=1, start_q=1, max_p=6, max_q=6,
m=12, start_P=0, seasonal=False,d=1, D=1, trace=True, error_action='ignore',
supress_warnings=True, stepwise=False)
```

O modelo mais adequado que o código apontou foi o ARIMA (0, 1, 1).

```
ARIMA(0,1,0)(0,0,0)[0] intercept : AIC=6378.379, Time=0.14 sec
ARIMA(0,1,1)(0,0,0)[0] intercept : AIC=6378.085, Time=0.36 sec
ARIMA(0,1,2)(0,0,0)[0] intercept : AIC=6378.694, Time=0.48 sec
ARIMA(0,1,3)(0,0,0)[0] intercept : AIC=6380.694, Time=0.63 sec
ARIMA(0,1,4)(0,0,0)[0] intercept : AIC=6381.979, Time=0.79 sec
ARIMA(0,1,5)(0,0,0)[0] intercept : AIC=6383.962, Time=1.07 sec
ARIMA(1,1,0)(0,0,0)[0] intercept : AIC=6378.218, Time=0.30 sec
ARIMA(1,1,1)(0,0,0)[0] intercept : AIC=6379.239, Time=1.52 sec
ARIMA(1,1,2)(0,0,0)[0] intercept : AIC=6380.695, Time=0.55 sec
ARIMA(1,1,3)(0,0,0)[0] intercept : AIC=6381.425, Time=3.10 sec
ARIMA(1,1,4)(0,0,0)[0] intercept : AIC=6383.988, Time=1.01 sec
ARIMA(2,1,0)(0,0,0)[0] intercept : AIC=6378.652, Time=0.44 sec
ARIMA(2,1,1)(0,0,0)[0] intercept : AIC=6380.642, Time=2.13 sec
ARIMA(2,1,2)(0,0,0)[0] intercept : AIC=6381.539, Time=3.53 sec
ARIMA(2,1,3)(0,0,0)[0] intercept : AIC=inf, Time=5.96 sec
ARIMA(3,1,0)(0,0,0)[0] intercept : AIC=6380.629, Time=0.54 sec
ARIMA(3,1,1)(0,0,0)[0] intercept : AIC=6382.633, Time=0.75 sec
ARIMA(3,1,2)(0,0,0)[0] intercept : AIC=6381.090, Time=4.92 sec
ARIMA(4,1,0)(0,0,0)[0] intercept : AIC=6382.056, Time=0.76 sec
ARIMA(4,1,1)(0,0,0)[0] intercept : AIC=6384.054, Time=0.88 sec
ARIMA(5,1,0)(0,0,0)[0] intercept : AIC=6384.055, Time=0.87 sec
```

```
Best model: ARIMA(0,1,1)(0,0,0)[0] intercept
Total fit time: 30.734 seconds
```

Foi definido o período de treino e teste, o modelo ideal apontado pelo Autoarima foi aplicado ao período de treino e, por fim, foi definido o período a ser predito.

```
trainarima=z.loc['2010-01-01':'2016-12-31']  
testarima=y.loc['2017-01-01':]  
  
stepwise_model.fit(trainarima)  
ARIMA(order=(0, 1, 1), scoring_args={}, suppress_warnings=True)  
  
future_forecastarima=stepwise_model.predict(n_periods=1095)
```

6. Apresentação dos Resultados

A seguir são apresentados os resultados por pacote.


6.1. Facebook Prophet

O seguinte código foi aplicado para reproduzir o resultado do modelo em gráfico.


```
prophet_forecast = prophet_model.make_future_dataframe(periods=1096, freq='D')
prophet_forecast = prophet_model.predict(prophet_forecast)

fig=prophet_model.plot(prophet_forecast)
ax1=fig.gca()
ax1.set_title('Previsão de cotação', fontsize=16)
ax1.set_xlabel('Período', fontsize=12)
ax1.set_ylabel('Preço de cotação', fontsize=12)
```


A seguir o gráfico contendo o período de treino e a predição.




A seguir o gráfico contendo os dados de treinamento, teste e a predição.



No gráfico seguinte é possível notar que a predição e teste apresentam um movimento lateral. Contudo, a predição não está precisa em relação aos dados de teste.



Abaixo dados sobre a tendência prevista, indicando que não seria nem de alta e nem de baixa, apenas lateral.



6.2. SKTIME


Foram utilizados três modelos preditivos do SKTIME: Naive, AutoETS e Theta. A seguir são apresentados os resultados de cada um deles.

a) NaiveForecaster


O seguinte código foi aplicado para reproduzir o resultado do modelo em gráfico.

```
forecaster = NaiveForecaster(strategy="last")
forecaster.fit(y_train)
y_pred = forecaster.predict(fh)
plot_series(y_train, y_test, y_pred, labels=["y_train", "y_test", "y_pred"])
smape_loss(y_pred, y_test)
```

A seguir o gráfico contendo os dados de treinamento, teste e a predição.



Apesar dos dados de teste oscilarem bastante, no gráfico seguinte é possível notar que a predição ignora oscilações e se apresenta como uma linha reta, cuja tendência é lateral, não indicando significativa alta e nem baixa no preço.



A seguir o erro obtido:

MAE: 6.2411254851228986
 MSE: 66.676482923674
 RMSE: 8.165566907672364


b) AutoETS

O seguinte código foi aplicado para reproduzir o resultado do modelo em gráfico.


```
from sktime.forecasting.ets import AutoETS

forecaster = AutoETS(auto=True, sp=12, n_jobs=-1)
forecaster.fit(y_train)
y_pred = forecaster.predict(fh)
plot_series(y_train, y_test, y_pred, labels=["y_train", "y_test", "y_pred"])
smape_loss(y_test, y_pred)
```

A seguir o gráfico contendo os dados de treinamento, teste e a predição.



Tal qual ocorreu no modelo Naive, apesar dos dados de teste oscilarem bastante, no gráfico seguinte é possível notar que a predição ignora oscilações e se apresenta como uma linha reta, cuja tendência é lateral, não indicando significativa alta e nem baixa no preço.



A seguir o erro obtido:


MAE: 6.3015513938898815
 MSE: 67.97582616714709
 RMSE: 8.244745367029056

c) ThetaForecaster


O seguinte código foi aplicado para reproduzir o resultado do modelo em gráfico.

```
forecaster = ThetaForecaster(sp=12)
forecaster.fit(y_train)
alpha = 0.05 # 95% prediction intervals
y_pred, pred_ints = forecaster.predict(fh, return_pred_int=True, alpha=alpha)
smape_loss(y_test, y_pred)
```

A seguir o gráfico contendo os dados de treinamento, teste e a predição.



No gráfico seguinte é possível notar que a predição e teste apresentam um movimento lateral. Contudo, a predição não está precisa em relação aos dados de teste.



A seguir o erro obtido:

MAE: 9.489329239173445
 MSE: 123.5232752885097
 RMSE: 11.114102540849156

6.3. Arima

O seguinte código foi aplicado para reproduzir o resultado do modelo em gráfico.

```
pd.concat([z, testarima, future_forecastarima], axis=1).plot(linewidth=3)
```

A seguir o gráfico contendo os dados de treinamento, teste e a predição.



No gráfico seguinte é possível notar que a predição e teste apresentam um movimento lateral. Contudo, a predição não está precisa em relação aos dados de teste.



A seguir o erro obtido:

MAE: 15.283343938135479
MSE: 319.1676593546785
RMSE: 17.86526404379959

7. Links

Abaixo os links para o repositório contendo os dados utilizados no projeto, scripts criados e para o vídeo de apresentação do TCC.

Link para o vídeo: <https://youtu.be/Uab8KaFgvT4>

Link para o repositório: <https://github.com/brunovc81/TCCPUC>

REFERÊNCIAS

FACEBOOK Prophet. Disponível em: <<https://opensource.facebook.com/>>. Acesso em: 15 de dezembro 2020.

<https://br.investing.com/commodities/crude-oil-historical-data> (acessado 01/12/2020)

<https://br.investing.com/commodities/brent-oil-historical-data> (acessado 01/12/2020)

https://github.com/alan-turing-institute/sktime/blob/master/examples/01_forecasting.ipynb (acessado 01/01/2021)

<https://www.youtube.com/watch?v=ccupZdvYCn4>(acessado 02/01/2021)

<https://www.youtube.com/watch?v=D9y6dcy0xK8>(acessado 03/01/2021)

https://github.com/aly2009/ModelosPreditivos-BolsaValores/blob/master/notebook_tcc.ipynb (acessado 04/01/2021)

<https://yiyibooks.cn/pyte/Pandas020/timeseries.html> (acessado 05/01/2021)

<https://www.xspdf.com/resolution/50067275.html> (acessado 06/01/2021)

<https://panda.ime.usp.br/algoritmos/static/algoritmos/03-adt3-arrays.html> (acessado 07/01/2021)

<https://jakevdp.github.io/PythonDataScienceHandbook/03.11-working-with-time-series.html> (acessado 08/01/2021)

<https://pt.stackoverflow.com/questions/438231/como-fazer-uma-sequencia-datas-no-python> (acessado 09/01/2021)

<https://stackoverflow.com/questions/22231592/pandas-change-data-type-of-series-to-string> (acessado 11/01/2021)

<https://pandas.pydata.org/pandas-docs/version/0.15.2/timeseries.html> (acessado 12/01/2021)

https://pandas.pydata.org/pandas-docs/version/0.25.3/user_guide/timeseries.html (acessado 13/01/2021)

APÊNDICE

In [2]: `!conda install -c conda-forge fbprophet -y`

```
Collecting package metadata (current_repodata.json): ...working... done
Solving environment: ...working... done
```

```
# All requested packages already installed.
```

In [3]: `!pip install --upgrade plotly`

```
Requirement already up-to-date: plotly in c:\users\bviei\anaconda3\lib\site-packages (4.14.3)
Requirement already satisfied, skipping upgrade: retrying>=1.3.3 in c:\users\bviei\anaconda3\lib\site-packages (from plotly) (1.3.3)
Requirement already satisfied, skipping upgrade: six in c:\users\bviei\anaconda3\lib\site-packages (from plotly) (1.15.0)
```

In [4]: `!pip install fbprophet`

```
Requirement already satisfied: fbprophet in c:\users\bviei\anaconda3\lib\site-packages (0.7.1)
Requirement already satisfied: LunarCalendar>=0.0.9 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (0.0.9)
Requirement already satisfied: matplotlib>=2.0.0 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (3.3.2)
Requirement already satisfied: convertdate>=2.1.2 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (2.1.3)
Requirement already satisfied: setuptools-git>=1.2 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (1.2)
Requirement already satisfied: holidays>=0.10.2 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (0.10.4)
Requirement already satisfied: numpy>=1.15.4 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (1.19.2)
Requirement already satisfied: python-dateutil>=2.8.0 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (2.8.1)
Requirement already satisfied: tqdm>=4.36.1 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (4.50.2)
Requirement already satisfied: Cython>=0.22 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (0.29.17)
Requirement already satisfied: pystan>=2.14 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (2.19.1.1)
Requirement already satisfied: pandas>=1.0.4 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (1.1.3)
Requirement already satisfied: cmdstanpy==0.9.5 in c:\users\bviei\anaconda3\lib\site-packages (from fbprophet) (0.9.5)
Requirement already satisfied: ephem>=3.7.5.3 in c:\users\bviei\anaconda3\lib\site-packages (from LunarCalendar>=0.0.9->fbprophet) (3.7.7.1)
Requirement already satisfied: pytz in c:\users\bviei\anaconda3\lib\site-packages (from LunarCalendar>=0.0.9->fbprophet) (2019.3)
Requirement already satisfied: kiwisolver>=1.0.1 in c:\users\bviei\anaconda3\lib\site-packages (from matplotlib>=2.0.0->fbprophet) (1.3.0)
Requirement already satisfied: certifi>=2020.06.20 in c:\users\bviei\anaconda3\lib\site-packages (from matplotlib>=2.0.0->fbprophet) (2020.12.5)
Requirement already satisfied: pillow>=6.2.0 in c:\users\bviei\anaconda3\lib\site-packages (from matplotlib>=2.0.0->fbprophet) (8.0.1)
Requirement already satisfied: pyparsing!=2.0.4,!=2.1.2,!=2.1.6,>=2.0.3 in c:\users\bviei\anaconda3\lib\site-packages (from matplotlib>=2.0.0->fbprophet) (2.4.7)
Requirement already satisfied: cyclical>=0.10 in c:\users\bviei\anaconda3\lib\site-packages (from matplotlib>=2.0.0->fbprophet) (0.10.0)
Requirement already satisfied: korean-lunar-calendar in c:\users\bviei\anaconda3\lib\site-packages (from holidays>=0.10.2->fbprophet) (0.2.1)
Requirement already satisfied: six in c:\users\bviei\anaconda3\lib\site-packages (from holidays>=0.10.2->fbprophet) (1.15.0)
```

```
In [5]: import pandas as pd
import numpy as np
from numpy import sqrt
import matplotlib.pyplot as plt
import plotly.offline as py
import plotly.graph_objs as go
py.init_notebook_mode(connected=True)

from statsmodels.tsa.arima_model import ARIMA
from statsmodels.tsa.stattools import adfuller
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.seasonal import seasonal_decompose
from pandas.plotting import lag_plot
!pip install pmdarima

import sklearn.metrics
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import mean_squared_error
from sklearn.metrics import r2_score
import statsmodels.api as sm
from scipy import stats

import warnings
warnings.filterwarnings("ignore")

from fbprophet import Prophet
from fbprophet.diagnostics import cross_validation, performance_metrics
from fbprophet.plot import plot_cross_validation_metric
```

Requirement already satisfied: pmdarima in c:\users\bviei\anaconda3\lib\site-packages (1.8.0)

Requirement already satisfied: joblib>=0.11 in c:\users\bviei\anaconda3\lib\site-packages (from pmdarima) (0.17.0)

Requirement already satisfied: numpy>=1.17.3 in c:\users\bviei\anaconda3\lib\site-packages (from pmdarima) (1.19.2)

Requirement already satisfied: pandas>=0.19 in c:\users\bviei\anaconda3\lib\site-packages (from pmdarima) (1.1.3)

Requirement already satisfied: scikit-learn>=0.22 in c:\users\bviei\anaconda3\lib\site-packages (from pmdarima) (0.23.2)

Requirement already satisfied: urllib3 in c:\users\bviei\anaconda3\lib\site-packages (from pmdarima) (1.25.11)

Requirement already satisfied: Cython<0.29.18,>=0.29 in c:\users\bviei\anaconda3\lib\site-packages (from pmdarima) (0.29.17)

Requirement already satisfied: statsmodels!=0.12.0,>=0.11 in c:\users\bviei\anaconda3\lib\site-packages (from pmdarima) (0.12.1)

Requirement already satisfied: setuptools!=50.0.0,>=38.6.0 in c:\users\bviei\anaconda3\lib\site-packages (from pmdarima) (50.3.1.post20201107)

Requirement already satisfied: scipy>=1.3.2 in c:\users\bviei\anaconda3\lib\site-packages (from pmdarima) (1.5.2)

Requirement already satisfied: python-dateutil>=2.7.3 in c:\users\bviei\anaconda3\lib\site-packages (from pandas>=0.19->pmdarima) (2.8.1)

Requirement already satisfied: pytz>=2017.2 in c:\users\bviei\anaconda3\lib\site-packages (from pandas>=0.19->pmdarima) (2019.3)

Requirement already satisfied: threadpoolctl>=2.0.0 in c:\users\bviei\anaconda3\lib\site-packages (from scikit-learn>=0.22->pmdarima) (2.1.0)

Requirement already satisfied: patsy>=0.5 in c:\users\bviei\anaconda3\lib\site-packages (from statsmodels!=0.12.0,>=0.11->pmdarima) (0.5.1)

Requirement already satisfied: six>=1.5 in c:\users\bviei\anaconda3\lib\site-packages (from python-dateutil>=2.7.3->pandas>=0.19->pmdarima) (1.15.0)

```
In [6]: brent = pd.read_csv("brent.csv", usecols=[0,1,2,3,4,5,6], decimal=",")
wti = pd.read_csv('wti.csv', usecols=[0,1,2,3,4,5,6], decimal=",")
```

In [7]: brent

Out[7]:

	Data	Último	Abertura	Máxima	Mínima	Vol.	Var%
0	31.12.2019	66.00	66.65	66.93	65.63	171,01K	-3,57%
1	30.12.2019	68.44	68.20	68.99	68.16	29,42K	0,41%
2	27.12.2019	68.16	67.91	68.33	67.57	112,22K	0,35%
3	26.12.2019	67.92	67.27	67.99	67.22	69,82K	1,07%
4	24.12.2019	67.20	66.44	67.26	66.36	104,94K	1,22%
...
2576	08.01.2010	81.37	81.51	82.05	80.59	157,49K	-0,17%
2577	07.01.2010	81.51	82.00	82.05	81.05	131,28K	-0,46%
2578	06.01.2010	81.89	80.38	82.21	79.77	157,87K	1,61%
2579	05.01.2010	80.59	80.29	80.84	79.75	131,75K	0,59%
2580	04.01.2010	80.12	78.49	80.48	78.34	122,64K	2,81%

2581 rows × 7 columns

In [8]: wti

Out[8]:

	Data	Último	Abertura	Máxima	Mínima	Vol.	Var%
0	31.12.2019	61.06	61.68	61.88	60.63	494,54K	-1,01%
1	30.12.2019	61.68	61.71	62.34	61.09	427,15K	-0,06%
2	27.12.2019	61.72	61.73	61.97	61.24	351,90K	0,06%
3	26.12.2019	61.68	61.20	61.83	61.06	265,09K	0,80%
4	25.12.2019	61.19	61.45	61.52	61.17	-	0,13%
...
2586	08.01.2010	82.75	82.65	83.47	81.80	310,38K	0,11%
2587	07.01.2010	82.66	83.20	83.36	82.26	246,63K	-0,63%
2588	06.01.2010	83.18	81.43	83.52	80.85	370,06K	1,72%
2589	05.01.2010	81.77	81.63	82.00	80.95	258,89K	0,32%
2590	04.01.2010	81.51	79.63	81.79	79.63	263,54K	2,71%

2591 rows × 7 columns

In [9]: *#DATAS - adequa as datas e também as define como index (o que facilitará a indentificação)*

```

brent['Data'] = pd.to_datetime(brent['Data'], format='%d.%m.%Y')
wti['Data'] = pd.to_datetime(wti['Data'], format='%d.%m.%Y')

```

```

brent.index = pd.to_datetime(brent.Data, format='%d.%m.%Y')
wti.index = pd.to_datetime(wti.Data, format='%d.%m.%Y')

brent.index.to_period('D')
wti.index.to_period('D')

```

```

Out[9]: PeriodIndex(['2019-12-31', '2019-12-30', '2019-12-27', '2019-12-26',
                    '2019-12-25', '2019-12-24', '2019-12-23', '2019-12-20',
                    '2019-12-19', '2019-12-18',
                    ...,
                    '2010-01-15', '2010-01-14', '2010-01-13', '2010-01-12',
                    '2010-01-11', '2010-01-08', '2010-01-07', '2010-01-06',
                    '2010-01-05', '2010-01-04'],
                    dtype='period[D]', name='Data', length=2591, freq='D')

```

```

In [10]: #CAMPOS COM VALORES - ajuste nos números e também no campo volume, que cotinha letras i
brent["Abertura"] = brent["Abertura"].astype(str)
brent["Último"] = brent["Último"].astype(str)
brent["Máxima"] = brent["Máxima"].astype(str)
brent["Mínima"] = brent["Mínima"].astype(str)
brent["Var%"] = brent["Var%"].astype(str)
brent["Vol."] = brent["Vol."].astype(str)

brent["Abertura"] = pd.Series(brent["Abertura"]).str.replace(',', '.', regex=True)
brent["Último"] = pd.Series(brent["Último"]).str.replace(',', '.', regex=True)
brent["Máxima"] = pd.Series(brent["Máxima"]).str.replace(',', '.', regex=True)
brent["Mínima"] = pd.Series(brent["Mínima"]).str.replace(',', '.', regex=True)
brent["Var%"] = pd.Series(brent["Var%"]).str.replace(',', '.', regex=True)
brent["Var%"] = pd.Series(brent["Var%"]).str.replace('%', '', regex=True)
brent["Vol."] = pd.Series(brent["Vol."]).str.replace('-', '', regex=True)
brent["Vol."] = pd.Series(brent["Vol."]).str.replace('.', '', regex=True)
brent["Vol."] = pd.Series(brent["Vol."]).str.replace('M', "000000", regex=True)
brent["Vol."] = pd.Series(brent["Vol."]).str.replace('K', "000", regex=True)
brent["Vol."] = pd.Series(brent["Vol."]).str.replace('B', "000000000", regex=True)

brent["Abertura"] = pd.to_numeric(brent["Abertura"])
brent["Último"] = pd.to_numeric(brent["Último"])
brent["Máxima"] = pd.to_numeric(brent["Máxima"])
brent["Mínima"] = pd.to_numeric(brent["Mínima"])
brent["Var%"] = pd.to_numeric(brent["Var%"])
brent["Vol."] = pd.to_numeric(brent["Vol."])

```

```

In [11]: #CAMPOS COM VALORES - ajuste nos números e também no campo volume, que cotinha letras i
wti["Abertura"] = wti["Abertura"].astype(str)
wti["Último"] = wti["Último"].astype(str)
wti["Máxima"] = wti["Máxima"].astype(str)
wti["Mínima"] = wti["Mínima"].astype(str)
wti["Var%"] = wti["Var%"].astype(str)
wti["Vol."] = wti["Vol."].astype(str)

wti["Abertura"] = pd.Series(wti["Abertura"]).str.replace(',', '.', regex=True)
wti["Último"] = pd.Series(wti["Último"]).str.replace(',', '.', regex=True)
wti["Máxima"] = pd.Series(wti["Máxima"]).str.replace(',', '.', regex=True)
wti["Mínima"] = pd.Series(wti["Mínima"]).str.replace(',', '.', regex=True)
wti["Var%"] = pd.Series(wti["Var%"]).str.replace(',', '.', regex=True)
wti["Var%"] = pd.Series(wti["Var%"]).str.replace('%', '', regex=True)
wti["Vol."] = pd.Series(wti["Vol."]).str.replace('-', '', regex=True)
wti["Vol."] = pd.Series(wti["Vol."]).str.replace('.', '', regex=True)
wti["Vol."] = pd.Series(wti["Vol."]).str.replace('M', "000000", regex=True)
wti["Vol."] = pd.Series(wti["Vol."]).str.replace('K', "000", regex=True)
wti["Vol."] = pd.Series(wti["Vol."]).str.replace('B', "000000000", regex=True)

```

```
wti["Vol."]=pd.Series(wti["Vol."]).str.replace('B',"000000000", regex=True)

wti["Abertura"] = pd.to_numeric(wti["Abertura"])
wti["Último"] = pd.to_numeric(wti["Último"])
wti["Máxima"] = pd.to_numeric(wti["Máxima"])
wti["Mínima"] = pd.to_numeric(wti["Mínima"])
wti["Var%"] = pd.to_numeric(wti["Var%"])
wti["Vol."] = pd.to_numeric(wti["Vol."])
```

In [12]: brent

Out[12]:

	Data	Último	Abertura	Máxima	Mínima	Vol.	Var%
	Data						
2019-12-31	2019-12-31	66.00	66.65	66.93	65.63	17101000.0	-3.57
2019-12-30	2019-12-30	68.44	68.20	68.99	68.16	2942000.0	0.41
2019-12-27	2019-12-27	68.16	67.91	68.33	67.57	11222000.0	0.35
2019-12-26	2019-12-26	67.92	67.27	67.99	67.22	6982000.0	1.07
2019-12-24	2019-12-24	67.20	66.44	67.26	66.36	10494000.0	1.22
...
2010-01-08	2010-01-08	81.37	81.51	82.05	80.59	15749000.0	-0.17
2010-01-07	2010-01-07	81.51	82.00	82.05	81.05	13128000.0	-0.46
2010-01-06	2010-01-06	81.89	80.38	82.21	79.77	15787000.0	1.61
2010-01-05	2010-01-05	80.59	80.29	80.84	79.75	13175000.0	0.59
2010-01-04	2010-01-04	80.12	78.49	80.48	78.34	12264000.0	2.81

2581 rows × 7 columns

In [13]: wti

Out[13]:

	Data	Último	Abertura	Máxima	Mínima	Vol.	Var%
	Data						
2019-12-31	2019-12-31	61.06	61.68	61.88	60.63	49454000.0	-1.01
2019-12-30	2019-12-30	61.68	61.71	62.34	61.09	42715000.0	-0.06
2019-12-27	2019-12-27	61.72	61.73	61.97	61.24	35190000.0	0.06
2019-12-26	2019-12-26	61.68	61.20	61.83	61.06	26509000.0	0.80
2019-12-25	2019-12-25	61.19	61.45	61.52	61.17	NaN	0.13
...
2010-01-08	2010-01-08	82.75	82.65	83.47	81.80	31038000.0	0.11
2010-01-07	2010-01-07	82.66	83.20	83.36	82.26	24663000.0	-0.63
2010-01-06	2010-01-06	83.18	81.43	83.52	80.85	37006000.0	1.72
2010-01-05	2010-01-05	81.77	81.63	82.00	80.95	25889000.0	0.32

	Data	Último	Abertura	Máxima	Mínima	Vol.	Var%
Data							
2010-01-04	2010-01-04	81.51	79.63	81.79	79.63	26354000.0	2.71

2591 rows × 7 columns

```
In [14]: brent.isnull().sum()
```

```
Out[14]: Data      0
Último    0
Abertura  0
Máxima    0
Mínima    0
Vol.      1
Var%      0
dtype: int64
```

```
In [15]: wti.isnull().sum()
```

```
Out[15]: Data      0
Último    0
Abertura  0
Máxima    0
Mínima    0
Vol.      74
Var%      0
dtype: int64
```

```
In [16]: brent_medianaMA = brent["Máxima"].rolling(5).mean().shift(-5).round(0)
brent_medianaMI = brent["Mínima"].rolling(5).mean().shift(-5).round(0)
brent_medianaAB = brent["Abertura"].rolling(5).mean().shift(-5).round(0)
brent_medianaUL = brent["Último"].rolling(5).mean().shift(-5).round(0)
brent_medianaVOL = brent["Vol."].rolling(5).mean().shift(-5).round(0)
brent["Máxima"].fillna(brent_medianaMA, inplace=True)
brent["Mínima"].fillna(brent_medianaMI, inplace=True)
brent["Abertura"].fillna(brent_medianaAB, inplace=True)
brent["Último"].fillna(brent_medianaUL, inplace=True)
brent["Vol."].fillna(brent_medianaVOL, inplace=True)
```

```
In [17]: wti_medianaMA = wti["Máxima"].rolling(5).mean().shift(-5).round(0)
wti_medianaMI = wti["Mínima"].rolling(5).mean().shift(-5).round(0)
wti_medianaAB = wti["Abertura"].rolling(5).mean().shift(-5).round(0)
wti_medianaUL = wti["Último"].rolling(5).mean().shift(-5).round(0)
wti_medianaVOL = wti["Vol."].rolling(5).mean().shift(-5).round(0)
wti["Máxima"].fillna(wti_medianaMA, inplace=True)
wti["Mínima"].fillna(wti_medianaMI, inplace=True)
wti["Abertura"].fillna(wti_medianaAB, inplace=True)
wti["Último"].fillna(wti_medianaUL, inplace=True)
wti["Vol."].fillna(wti_medianaVOL, inplace=True)
```

```
In [18]: brent.isnull().sum()
```

```
Out[18]: Data      0
Último    0
Abertura  0
Máxima    0
Mínima    0
Vol.      0
```



```
Var%      0
dtype: int64
```

```
In [19]: wti.isnull().sum()
```

```
Out[19]: Data      0
Último      0
Abertura    0
Máxima      0
Mínima      0
Vol.        27
Var%        0
dtype: int64
```

```
In [20]: wti_medianaVOL = wti["Vol."].rolling(5).mean().shift(-5).round(0)
wti["Vol."].fillna(wti_medianaVOL, inplace=True)
```

```
In [21]: wti.isnull().sum()
```

```
Out[21]: Data      0
Último      0
Abertura    0
Máxima      0
Mínima      0
Vol.         1
Var%        0
dtype: int64
```

```
In [22]: wti_medianaVOL = wti["Vol."].rolling(5).mean().shift(-5).round(0)
wti["Vol."].fillna(wti_medianaVOL, inplace=True)
```

```
In [23]: wti.isnull().sum()
```

```
Out[23]: Data      0
Último      0
Abertura    0
Máxima      0
Mínima      0
Vol.         0
Var%        0
dtype: int64
```

```
In [24]: #JUNÇÃO DAS TABELAS, cria dataset bw

brent.rename(columns= {'Data': 'data'}, inplace=True)
wti.rename(columns= {'Data': 'data'}, inplace=True)

bw = pd.merge(brent,wti,how='inner', on=['data'],suffixes=('_B', '_W'))
```

```
In [25]: bw.isnull().sum()
```

```
Out[25]: data      0
Último_B      0
Abertura_B     0
Máxima_B      0
Mínima_B      0
Vol._B         0
Var%_B         0
Último_W      0
Abertura_W     0
Máxima_W      0
Mínima_W      0
```

Vol._W 0
Var%_W 0
dtype: int64

```
In [26]: bw
```

Out[26]:		data	Último_B	Abertura_B	Máxima_B	Mínima_B	Vol._B	Var%_B	Último_W	Abertura_W
	0	2019-12-31	66.00	66.65	66.93	65.63	17101000.0	-3.57	61.06	61.68
	1	2019-12-30	68.44	68.20	68.99	68.16	2942000.0	0.41	61.68	61.71
	2	2019-12-27	68.16	67.91	68.33	67.57	11222000.0	0.35	61.72	61.73
	3	2019-12-26	67.92	67.27	67.99	67.22	6982000.0	1.07	61.68	61.20
	4	2019-12-24	67.20	66.44	67.26	66.36	10494000.0	1.22	61.11	60.63

	2555	2010-01-08	81.37	81.51	82.05	80.59	15749000.0	-0.17	82.75	82.65
	2556	2010-01-07	81.51	82.00	82.05	81.05	13128000.0	-0.46	82.66	83.20
	2557	2010-01-06	81.89	80.38	82.21	79.77	15787000.0	1.61	83.18	81.43
	2558	2010-01-05	80.59	80.29	80.84	79.75	13175000.0	0.59	81.77	81.63
	2559	2010-01-04	80.12	78.49	80.48	78.34	12264000.0	2.81	81.51	79.63

2560 rows × 13 columns



```
In [27]: bw.index = pd.to_datetime(bw.data, format='%d.%m.%Y')
```

```
In [28]: bw
```

Out[28]:		data	Último_B	Abertura_B	Máxima_B	Mínima_B	Vol._B	Var%_B	Último_W	Abertura_W
		data								
	2019-12-31	2019-12-31	66.00	66.65	66.93	65.63	17101000.0	-3.57	61.06	61.68
	2019-12-30	2019-12-30	68.44	68.20	68.99	68.16	2942000.0	0.41	61.68	61.71
	2019-12-27	2019-12-27	68.16	67.91	68.33	67.57	11222000.0	0.35	61.72	61.73
	2019-12-26	2019-12-26	67.92	67.27	67.99	67.22	6982000.0	1.07	61.68	61.20

02/02/2021

TCC_FINALIZADO

	data	Último_B	Abertura_B	Máxima_B	Mínima_B	Vol._B	Var%_B	Último_W	Abertura_W
	data								
2019-12-24	2019-12-24	67.20	66.44	67.26	66.36	10494000.0	1.22	61.11	60.63
...
2010-01-08	2010-01-08	81.37	81.51	82.05	80.59	15749000.0	-0.17	82.75	82.65
2010-01-07	2010-01-07	81.51	82.00	82.05	81.05	13128000.0	-0.46	82.66	83.20
2010-01-06	2010-01-06	81.89	80.38	82.21	79.77	15787000.0	1.61	83.18	81.43
2010-01-05	2010-01-05	80.59	80.29	80.84	79.75	13175000.0	0.59	81.77	81.63
2010-01-04	2010-01-04	80.12	78.49	80.48	78.34	12264000.0	2.81	81.51	79.63

2560 rows × 13 columns



```
In [29]: brent1 = pd.DataFrame(columns={"data", "Abertura_B", "Máxima_B", "Mínima_B", "Último_B",
brent1["data"] = bw["data"]
brent1["Abertura_B"] = bw["Abertura_B"]
brent1["Máxima_B"] = bw["Máxima_B"]
brent1["Mínima_B"] = bw["Mínima_B"]
brent1["Último_B"] = bw["Último_B"]
brent1["Vol._B"] = bw["Vol._B"]
```

```
In [30]: brent1
```

Out[30]:

	Abertura_B	Último_B	Máxima_B	data	Vol._B	Mínima_B
data						
2019-12-31	66.65	66.00	66.93	2019-12-31	17101000.0	65.63
2019-12-30	68.20	68.44	68.99	2019-12-30	2942000.0	68.16
2019-12-27	67.91	68.16	68.33	2019-12-27	11222000.0	67.57
2019-12-26	67.27	67.92	67.99	2019-12-26	6982000.0	67.22
2019-12-24	66.44	67.20	67.26	2019-12-24	10494000.0	66.36
...
2010-01-08	81.51	81.37	82.05	2010-01-08	15749000.0	80.59
2010-01-07	82.00	81.51	82.05	2010-01-07	13128000.0	81.05
2010-01-06	80.38	81.89	82.21	2010-01-06	15787000.0	79.77
2010-01-05	80.29	80.59	80.84	2010-01-05	13175000.0	79.75
2010-01-04	78.49	80.12	80.48	2010-01-04	12264000.0	78.34

2560 rows × 6 columns

```
In [31]: wti1 = pd.DataFrame(columns=["data", "Abertura_W", "Máxima_W", "Mínima_W", "Último_W", "V
wti1["data"] = bw["data"]
wti1["Abertura_W"] = bw["Abertura_W"]
wti1["Máxima_W"] = bw["Máxima_W"]
wti1["Mínima_W"] = bw["Mínima_W"]
wti1["Último_W"] = bw["Último_W"]
wti1["Vol._W"] = bw["Vol._W"]
```

```
In [32]: wti1
```

```
Out[32]:
```

	Mínima_W	data	Abertura_W	Vol._W	Máxima_W	Último_W
data						
2019-12-31	60.63	2019-12-31	61.68	49454000.0	61.88	61.06
2019-12-30	61.09	2019-12-30	61.71	42715000.0	62.34	61.68
2019-12-27	61.24	2019-12-27	61.73	35190000.0	61.97	61.72
2019-12-26	61.06	2019-12-26	61.20	26509000.0	61.83	61.68
2019-12-24	60.47	2019-12-24	60.63	20454000.0	61.16	61.11
...
2010-01-08	81.80	2010-01-08	82.65	31038000.0	83.47	82.75
2010-01-07	82.26	2010-01-07	83.20	24663000.0	83.36	82.66
2010-01-06	80.85	2010-01-06	81.43	37006000.0	83.52	83.18
2010-01-05	80.95	2010-01-05	81.63	25889000.0	82.00	81.77
2010-01-04	79.63	2010-01-04	79.63	26354000.0	81.79	81.51

2560 rows × 6 columns

```
In [33]: brent1.rename(columns= {'data': 'Data'}, inplace=True)
wti1.rename(columns= {'data': 'Data'}, inplace=True)
```

```
In [34]: brent1
```

```
Out[34]:
```

	Abertura_B	Último_B	Máxima_B	Data	Vol._B	Mínima_B
data						
2019-12-31	66.65	66.00	66.93	2019-12-31	17101000.0	65.63
2019-12-30	68.20	68.44	68.99	2019-12-30	2942000.0	68.16
2019-12-27	67.91	68.16	68.33	2019-12-27	11222000.0	67.57
2019-12-26	67.27	67.92	67.99	2019-12-26	6982000.0	67.22
2019-12-24	66.44	67.20	67.26	2019-12-24	10494000.0	66.36
...
2010-01-08	81.51	81.37	82.05	2010-01-08	15749000.0	80.59

	Abertura_B	Último_B	Máxima_B	Data	Vol._B	Mínima_B
data						
2010-01-07	82.00	81.51	82.05	2010-01-07	13128000.0	81.05
2010-01-06	80.38	81.89	82.21	2010-01-06	15787000.0	79.77
2010-01-05	80.29	80.59	80.84	2010-01-05	13175000.0	79.75
2010-01-04	78.49	80.12	80.48	2010-01-04	12264000.0	78.34

2560 rows × 6 columns

```
In [35]: #Serparar treino e teste

filtroB = brent1['Data']<= "2016-12-31"
train_B = brent1[filtroB]

filtroW = wti1['Data']<= "2016-12-31"
train_W = wti1[filtroW]

filtroBteste = brent1['Data']> "2016-12-31"
teste_B = brent1[filtroBteste]

filtroWteste = wti1['Data']> "2016-12-31"
teste_W = wti1[filtroWteste]
```

```
In [36]: #correlação

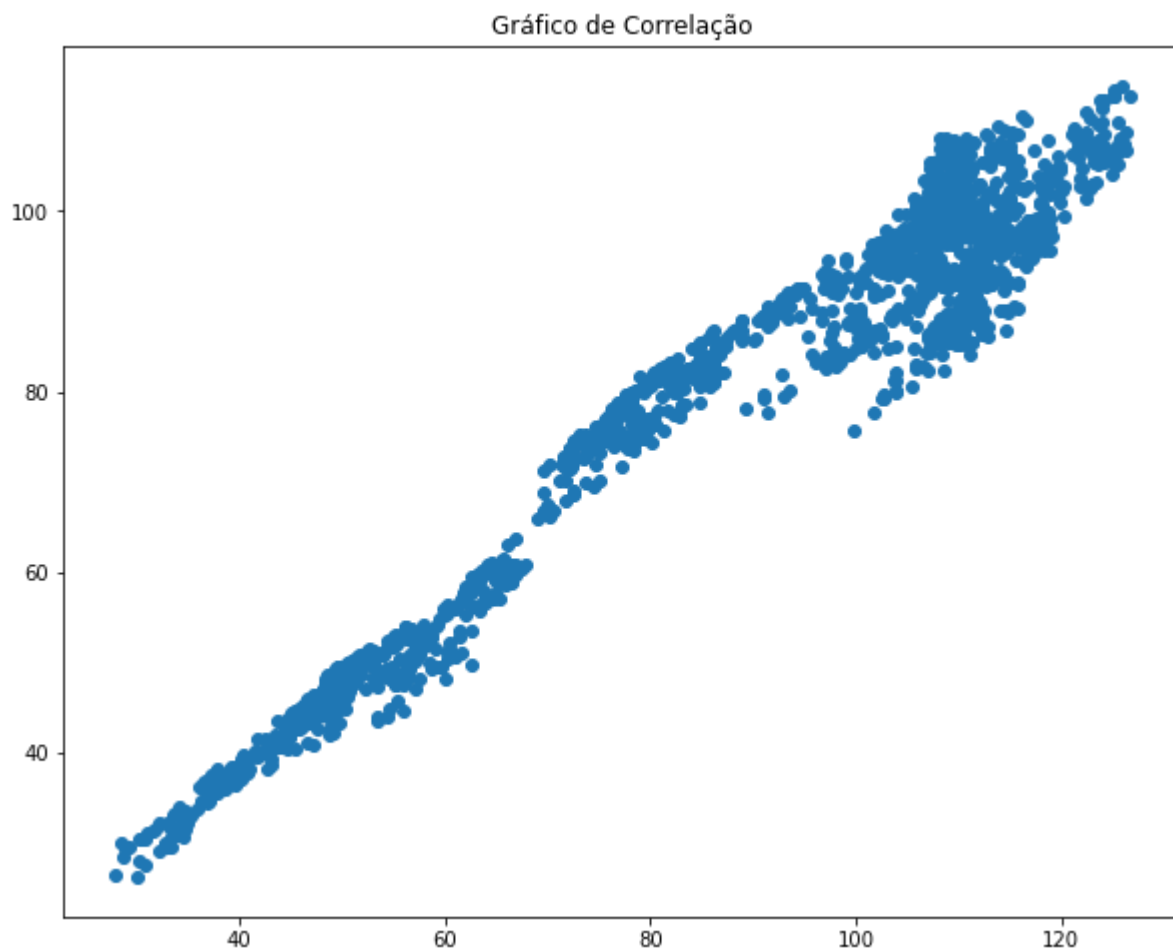
train_B["Último_B"].corr(train_W["Último_W"])
```

Out[36]: 0.9745391323161525


```
In [37]: data1=train_B["Último_B"]
data2=train_W["Último_W"]

plt.scatter(data1, data2)
plt.title('Gráfico de Correlação')
plt.gcf().set_size_inches(10, 8)
plt.show()

#diretamente proporcionais com alta correlação
```



```
In [38]: eixo_x = train_B['Data']  
linha_brent1_ultimo = train_B["Último_B"]  
linha_wti1_ultimo = train_W["Último_W"]  
trace1 = go.Scatter(x = eixo_x,y = linha_brent1_ultimo,mode = 'lines', name = 'BRENT')  
trace2 = go.Scatter(x = eixo_x,y = linha_wti1_ultimo,mode = 'lines',name = 'WTI')  
data = [trace1, trace2]  
py.iplot(data)
```



In [39]: `train_B.describe()`

Out[39]:

	Abertura_B	Último_B	Máxima_B	Vol_B	Mínima_B
count	1787.000000	1787.000000	1787.000000	1.787000e+03	1787.000000
mean	86.967857	86.978215	87.963212	1.943510e+07	85.900235
std	27.278378	27.329470	27.340258	7.398364e+06	27.210115
min	27.990000	27.880000	28.750000	1.152000e+06	27.100000
25%	59.580000	59.230000	60.560000	1.535850e+07	58.375000
50%	99.540000	99.650000	100.620000	1.950300e+07	97.920000
75%	109.760000	109.885000	110.800000	2.356550e+07	108.900000
max	126.580000	126.650000	128.400000	4.638100e+07	125.000000

In [40]: `import plotly.graph_objects as go`


```
fig = go.Figure(data=[go.Candlestick(x=train_B['Data'],
                                     open=train_B['Abertura_B'], high=train_B['Máxima_B'],
                                     low=train_B['Mínima_B'], close=train_B["Último_B"])
                    ])

fig.update_layout(xaxis_rangeslider_visible=False)
fig.show()
```



```
In [41]: import seaborn as sns
plt.figure(figsize=(10,7))
sns.set_context("notebook", font_scale=1.5, rc={'font.size':20, 'axes.titlesize':20, 'a
sns.rugplot(train_B["Último_B"], color = 'red')
sns.distplot(train_B["Último_B"], color = 'green')
sns.set_style("darkgrid")
plt.title("Distribuição de Fechamento - BRENT")
```

Out[41]: Text(0.5, 1.0, 'Distribuição de Fechamento - BRENT')



```
In [42]: #gráfico com dois eixos y

b = train_B["Data"]
data1 = train_B["Último_B"]
data2 = train_B["Vol._B"]
```




```
fig, ax1 = plt.subplots()

color = 'tab:red'
ax1.set_xlabel('')
ax1.set_ylabel('Preço', color=color)
ax1.plot(b, data1, color=color)
ax1.tick_params(axis='y', labelcolor=color)

ax2 = ax1.twinx()

color = 'tab:blue'
ax2.set_ylabel('Volume', color=color)
ax2.plot(b, data2, color=color)
ax2.tick_params(axis='y', labelcolor=color)
plt.gcf().set_size_inches(15, 10)
plt.show()
```




```
In [43]: train_W.describe()
```

	Mínima_W	Abertura_W	Vol._W	Máxima_W	Último_W
count	1787.000000	1787.000000	1.787000e+03	1787.000000	1787.000000
mean	77.664057	78.779239	3.200921e+07	79.767185	78.753643
std	22.891260	22.954251	1.581953e+07	22.972323	22.978843
min	26.050000	27.300000	2.210000e+06	27.480000	26.210000
25%	52.055000	53.045000	2.244200e+07	54.005000	53.000000
50%	85.550000	86.570000	2.941880e+07	87.770000	86.670000
75%	96.260000	97.310000	3.937150e+07	98.065000	97.330000

	Mínima_W	Abertura_W	Vol._W	Máxima_W	Último_W
max	112.250000	113.890000	1.310000e+08	114.830000	113.930000

```
In [44]: plt.figure(figsize=(10,7))
sns.set_context("notebook", font_scale=1.5, rc={'font.size':20, 'axes.titlesize':20, 'a
sns.rugplot(train_W["Último_W"], color='red')
sns.distplot(train_W["Último_W"], color='green')
sns.set_style("darkgrid")
plt.title("Distribuição de Fechamento - WTI")
```

```
Out[44]: Text(0.5, 1.0, 'Distribuição de Fechamento - WTI')
```



```
In [45]: import plotly.graph_objects as go

fig = go.Figure(data=[go.Candlestick(x=train_W['Data'],
open=train_W['Abertura_W'], high=train_W['Máxima_W'],
low=train_W['Mínima_W'], close=train_W["Último_W"])
])

fig.update_layout(xaxis_rangeslider_visible=False)
fig.show()
```




```
In [46]: w = train_W["Data"]
data1 = train_W["Último_W"]
data2 = train_W["Vol._W"]

fig, ax1 = plt.subplots()

color = 'tab:red'
ax1.set_xlabel('')
ax1.set_ylabel('Preço', color=color)
ax1.plot(w, data1, color=color)
ax1.tick_params(axis='y', labelcolor=color)

ax2 = ax1.twinx()

color = 'tab:blue'
ax2.set_ylabel('Volume', color=color)
ax2.plot(w, data2, color=color)
ax2.tick_params(axis='y', labelcolor=color)
plt.gcf().set_size_inches(15, 10)
plt.show()
```



FACEBOOK PROPHET

```
In [47]: train_start_date = '2010-01-01'
train_end_date = '2016-12-31'

test_start_date = '2017-01-01'
test_end_date = '2019-12-31'
```

```
In [48]: brent2 = brent1
```

```
In [49]: brent2
```

```
Out[49]:
```

	Abertura_B	Último_B	Máxima_B	Data	Vol_B	Mínima_B
data						
2019-12-31	66.65	66.00	66.93	2019-12-31	17101000.0	65.63
2019-12-30	68.20	68.44	68.99	2019-12-30	2942000.0	68.16
2019-12-27	67.91	68.16	68.33	2019-12-27	11222000.0	67.57
2019-12-26	67.27	67.92	67.99	2019-12-26	6982000.0	67.22
2019-12-24	66.44	67.20	67.26	2019-12-24	10494000.0	66.36
...
2010-01-08	81.51	81.37	82.05	2010-01-08	15749000.0	80.59
2010-01-07	82.00	81.51	82.05	2010-01-07	13128000.0	81.05
2010-01-06	80.38	81.89	82.21	2010-01-06	15787000.0	79.77
2010-01-05	80.29	80.59	80.84	2010-01-05	13175000.0	79.75

	Abertura_B	Último_B	Máxima_B	Data	Vol._B	Mínima_B
data						
2010-01-04	78.49	80.12	80.48	2010-01-04	12264000.0	78.34

2560 rows × 6 columns

```
In [50]: filtroB2 = brent2['Data'] <= train_end_date
         train_B2 = brent2[filtroB2]

         filtroB2teste = brent2['Data'] > train_end_date
         teste_B2 = brent2[filtroB2teste]
```

```
In [51]: train_B2.drop(columns=["Máxima_B", "Abertura_B", "Mínima_B", "Vol._B"])
```

```
Out[51]:
```

	Último_B	Data
--	----------	------

data		
2016-12-30	56.82	2016-12-30
2016-12-29	56.14	2016-12-29
2016-12-28	56.22	2016-12-28
2016-12-27	56.09	2016-12-27
2016-12-23	55.16	2016-12-23
...
2010-01-08	81.37	2010-01-08
2010-01-07	81.51	2010-01-07
2010-01-06	81.89	2010-01-06
2010-01-05	80.59	2010-01-05
2010-01-04	80.12	2010-01-04

1787 rows × 2 columns

```
In [52]: teste_B2.drop(columns=["Máxima_B", "Abertura_B", "Mínima_B", "Vol._B"])
```

```
Out[52]:
```

	Último_B	Data
--	----------	------

data		
2019-12-31	66.00	2019-12-31
2019-12-30	68.44	2019-12-30
2019-12-27	68.16	2019-12-27
2019-12-26	67.92	2019-12-26
2019-12-24	67.20	2019-12-24
...

	Último_B	Data
data		
2017-01-09	54.94	2017-01-09
2017-01-06	57.10	2017-01-06
2017-01-05	56.89	2017-01-05
2017-01-04	56.46	2017-01-04
2017-01-03	55.47	2017-01-03

773 rows × 2 columns

```
In [53]: train_B2_FP = pd.DataFrame({"ds":train_B2['Data'], "y":train_B2['Último_B']})
train_B2_FP.reset_index(drop=True, inplace=True)
train_B2_FP
```

```
Out[53]:
```

	ds	y
0	2016-12-30	56.82
1	2016-12-29	56.14
2	2016-12-28	56.22
3	2016-12-27	56.09
4	2016-12-23	55.16
...
1782	2010-01-08	81.37
1783	2010-01-07	81.51
1784	2010-01-06	81.89
1785	2010-01-05	80.59
1786	2010-01-04	80.12

1787 rows × 2 columns

```
In [54]: teste_B2_FP = pd.DataFrame({"ds_teste":teste_B2['Data'], "y_teste":teste_B2['Último_B']})
teste_B2_FP.reset_index(drop=True, inplace=True)
teste_B2_FP
```

```
Out[54]:
```

	ds_teste	y_teste
0	2019-12-31	66.00
1	2019-12-30	68.44
2	2019-12-27	68.16
3	2019-12-26	67.92
4	2019-12-24	67.20
...

	ds_teste	y_teste
768	2017-01-09	54.94
769	2017-01-06	57.10
770	2017-01-05	56.89
771	2017-01-04	56.46
772	2017-01-03	55.47

773 rows × 2 columns


```
In [55]: prophet_model = Prophet(changepoint_prior_scale=0.05, interval_width=0.95, daily_season
prophet_model.fit(train_B2_FP)
```

```
Out[55]: <fbprophet.forecaster.Prophet at 0x26f7ad79cd0>
```

```
In [56]: prophet_forecast = prophet_model.make_future_dataframe(periods=1096, freq='D')
prophet_forecast = prophet_model.predict(prophet_forecast)

fig=prophet_model.plot(prophet_forecast)
ax1=fig.gca()
ax1.set_title('Previsão de cotação', fontsize=16)
ax1.set_xlabel('Período', fontsize=12)
ax1.set_ylabel('Preço de cotação', fontsize=12)
```

```
Out[56]: Text(39.5, 0.5, 'Preço de cotação')
```




```
In [57]: prophet_forecast = prophet_forecast[prophet_forecast['ds'] > train_end_date]
prophet_forecast.head()
```


```
Out[57]:
```

ds	trend	yhat_lower	yhat_upper	trend_lower	trend_upper	additive_terms	additive_tern
----	-------	------------	------------	-------------	-------------	----------------	---------------

	ds	trend	yhat_lower	yhat_upper	trend_lower	trend_upper	additive_terms	additive_tern
1788	2017-01-01	46.522636	32.271853	54.417461	46.522636	46.522636	-3.394820	-
1789	2017-01-02	46.522401	31.804644	53.528329	46.522401	46.522401	-3.689596	-
1790	2017-01-03	46.522166	31.753264	53.856961	46.522166	46.522166	-3.798483	-
1791	2017-01-04	46.521930	31.267200	53.303155	46.521930	46.523158	-3.851718	-
1792	2017-01-05	46.521695	31.252054	53.775329	46.518990	46.529545	-3.991363	-




In [58]: `fig=prophet_model.plot_components(prophet_forecast)`




In [59]: `prophet_forecast.set_index(prophet_forecast['ds'], inplace=True)`


```
teste_B2_FP.set_index(teste_B2_FP['ds_teste'], inplace=True)
train_B2_FP.set_index(train_B2_FP['ds'], inplace=True)
```

```
In [60]: n = train_B2_FP.shape[0]
plt.figure(figsize=(14,8))
plt.title("Treino x Predição x Teste")
plt.plot(train_B2_FP['y'], 'green', label='Treino')
plt.plot(teste_B2_FP['y_teste'], 'blue', label='Teste')
plt.plot(prophet_forecast['yhat'], 'red', label='Predição')
plt.fill_between(prophet_forecast.index, prophet_forecast['yhat_lower'], prophet_foreca
plt.legend()
plt.grid(True)
```



```
In [61]: plt.figure(figsize=(14,8))
plt.plot(teste_B2_FP['y_teste'], 'blue', label='Teste')
plt.plot(prophet_forecast['yhat'], 'red', label='Predição')
plt.fill_between(prophet_forecast.index, prophet_forecast['yhat_lower'], prophet_foreca
plt.legend()
plt.grid(True)
```



```
In [63]: pf = prophet_forecast.copy()
tb2 = teste_B2_FP.copy()

pf.rename(columns= {'ds': 'data'}, inplace=True)
tb2.rename(columns= {'ds_teste': 'data'}, inplace=True)

pftb2 = pd.merge(pf,tb2,how='inner', on=['data'],suffixes=('_P', '_T'))
pftb2
```

```
Out[63]:
```

	data	trend	yhat_lower	yhat_upper	trend_lower	trend_upper	additive_terms	additive_term
0	2017-01-03	46.522166	31.753264	53.856961	46.522166	46.522166	-3.798483	-3
1	2017-01-04	46.521930	31.267200	53.303155	46.521930	46.523158	-3.851718	-3
2	2017-01-05	46.521695	31.252054	53.775329	46.518990	46.529545	-3.991363	-3
3	2017-01-06	46.521460	30.806468	52.818402	46.500924	46.541872	-4.266456	-4
4	2017-01-09	46.520755	30.199963	53.182456	46.422887	46.607116	-5.097600	-5
...
768	2019-12-24	46.267069	-140.691328	229.004072	-139.839156	230.808042	-2.731992	-2
769	2019-12-26	46.266599	-140.823405	233.369853	-140.121356	231.242182	-2.607993	-2
770	2019-12-27	46.266364	-143.319539	227.894682	-140.260581	231.459252	-2.729845	-2
771	2019-12-30	46.265659	-148.020037	227.181423	-140.970103	232.110462	-3.169816	-3

	data	trend	yhat_lower	yhat_upper	trend_lower	trend_upper	additive_terms	additive_term
772	2019-12-31	46.265424	-142.323374	234.443056	-141.216303	232.327532	-3.220225	-3

773 rows × 20 columns

```
In [64]: #Cálculo do erro
print('MAE: ', mean_absolute_error(pftb2['y_teste'],pftb2['yhat']))
print('MSE: ', mean_squared_error(pftb2['y_teste'],pftb2['yhat']))
print('RMSE: ', np.sqrt(mean_squared_error(pftb2['y_teste'],pftb2['yhat'])))

MAE: 17.145523353934433
MSE: 373.3109475977907
RMSE: 19.321256366959958
```

SKTIME

```
In [65]: pip install sktime

Requirement already satisfied: sktime in c:\users\bviei\anaconda3\lib\site-packages (0.5.2)
Requirement already satisfied: numba>=0.50 in c:\users\bviei\anaconda3\lib\site-packages (from sktime) (0.51.2)
Requirement already satisfied: wheel in c:\users\bviei\anaconda3\lib\site-packages (from sktime) (0.35.1)
Requirement already satisfied: pandas>=1.1.0 in c:\users\bviei\anaconda3\lib\site-packages (from sktime) (1.1.3)
Requirement already satisfied: statsmodels>=0.12.1 in c:\users\bviei\anaconda3\lib\site-packages (from sktime) (0.12.1)
Requirement already satisfied: scikit-learn>=0.23.0 in c:\users\bviei\anaconda3\lib\site-packages (from sktime) (0.23.2)
Requirement already satisfied: numpy>=1.19.0 in c:\users\bviei\anaconda3\lib\site-packages (from sktime) (1.19.2)
Requirement already satisfied: llvmlite<0.35,>=0.34.0.dev0 in c:\users\bviei\anaconda3\lib\site-packages (from numba>=0.50->sktime) (0.34.0)
Requirement already satisfied: setuptools in c:\users\bviei\anaconda3\lib\site-packages (from numba>=0.50->sktime) (50.3.1.post20201107)
Requirement already satisfied: python-dateutil>=2.7.3 in c:\users\bviei\anaconda3\lib\site-packages (from pandas>=1.1.0->sktime) (2.8.1)
Requirement already satisfied: pytz>=2017.2 in c:\users\bviei\anaconda3\lib\site-packages (from pandas>=1.1.0->sktime) (2019.3)
Requirement already satisfied: scipy>=1.1 in c:\users\bviei\anaconda3\lib\site-packages (from statsmodels>=0.12.1->sktime) (1.5.2)
Requirement already satisfied: patsy>=0.5 in c:\users\bviei\anaconda3\lib\site-packages (from statsmodels>=0.12.1->sktime) (0.5.1)
Requirement already satisfied: threadpoolctl>=2.0.0 in c:\users\bviei\anaconda3\lib\site-packages (from scikit-learn>=0.23.0->sktime) (2.1.0)
Requirement already satisfied: joblib>=0.11 in c:\users\bviei\anaconda3\lib\site-packages (from scikit-learn>=0.23.0->sktime) (0.17.0)
Requirement already satisfied: six>=1.5 in c:\users\bviei\anaconda3\lib\site-packages (from python-dateutil>=2.7.3->pandas>=1.1.0->sktime) (1.15.0)
Note: you may need to restart the kernel to use updated packages.
```

```
In [66]: from sktime.forecasting.arima import ARIMA, AutoARIMA
from sktime.forecasting.base import ForecastingHorizon
from sktime.forecasting.compose import (
    EnsembleForecaster,
    ReducedRegressionForecaster,
```

```

    TransformedTargetForecaster,
)
from sktime.forecasting.exp_smoothing import ExponentialSmoothing
from sktime.forecasting.model_selection import (
    ForecastingGridSearchCV,
    SlidingWindowSplitter,
    temporal_train_test_split,
)
from sktime.forecasting.naive import NaiveForecaster
from sktime.forecasting.theta import ThetaForecaster
from sktime.forecasting.trend import PolynomialTrendForecaster
from sktime.performance_metrics.forecasting import SMAPE, smape_loss
from sktime.transformations.series.detrend import Deseasonalizer, Detrender
from sktime.utils.plotting import plot_series

%matplotlib inline

```

```

In [135... train_B3=train_B2
           teste_B3=teste_B2

           y_trainSK=train_B3
           y_testSK=teste_B3

```

```

In [136... y_testSK

```

```

Out[136...

```

	Abertura_B	Último_B	Máxima_B	Data	Vol._B	Mínima_B
data						
2019-12-31	66.65	66.00	66.93	2019-12-31	17101000.0	65.63
2019-12-30	68.20	68.44	68.99	2019-12-30	2942000.0	68.16
2019-12-27	67.91	68.16	68.33	2019-12-27	11222000.0	67.57
2019-12-26	67.27	67.92	67.99	2019-12-26	6982000.0	67.22
2019-12-24	66.44	67.20	67.26	2019-12-24	10494000.0	66.36
...
2017-01-09	56.81	54.94	57.00	2017-01-09	26639000.0	54.74
2017-01-06	56.88	57.10	57.47	2017-01-06	23487000.0	56.28
2017-01-05	56.35	56.89	57.35	2017-01-05	26961000.0	56.01
2017-01-04	55.73	56.46	56.55	2017-01-04	28255000.0	55.33
2017-01-03	57.05	55.47	58.37	2017-01-03	34082000.0	55.30

773 rows × 6 columns

```

In [137... y_trainSK=y_trainSK.drop(columns=["Máxima_B", "Abertura_B", "Mínima_B", "Vol._B"])
           y_testSK=y_testSK.drop(columns=["Máxima_B", "Abertura_B", "Mínima_B", "Vol._B"])

```

```

In [138... y_trainSK

```

```

Out[138...

```

	Último_B	Data
data		

	Último_B	Data
data		
2016-12-30	56.82	2016-12-30
2016-12-29	56.14	2016-12-29
2016-12-28	56.22	2016-12-28
2016-12-27	56.09	2016-12-27
2016-12-23	55.16	2016-12-23
...
2010-01-08	81.37	2010-01-08
2010-01-07	81.51	2010-01-07
2010-01-06	81.89	2010-01-06
2010-01-05	80.59	2010-01-05
2010-01-04	80.12	2010-01-04

1787 rows × 2 columns

```
In [139... y_trainI = y_trainSK.sort_values(by='Data')
y_trainI
```

	Último_B	Data
data		
2010-01-04	80.12	2010-01-04
2010-01-05	80.59	2010-01-05
2010-01-06	81.89	2010-01-06
2010-01-07	81.51	2010-01-07
2010-01-08	81.37	2010-01-08
...
2016-12-23	55.16	2016-12-23
2016-12-27	56.09	2016-12-27
2016-12-28	56.22	2016-12-28
2016-12-29	56.14	2016-12-29
2016-12-30	56.82	2016-12-30

1787 rows × 2 columns

```
In [140... y_testI = y_testSK.sort_values(by='Data')
y_testI
```

	Último_B	Data
--	----------	------

data	Último_B	Data
<hr/>		
data		
<hr/>		
2017-01-03	55.47	2017-01-03
2017-01-04	56.46	2017-01-04
2017-01-05	56.89	2017-01-05
2017-01-06	57.10	2017-01-06
2017-01-09	54.94	2017-01-09
...
2019-12-24	67.20	2019-12-24
2019-12-26	67.92	2019-12-26
2019-12-27	68.16	2019-12-27
2019-12-30	68.44	2019-12-30
2019-12-31	66.00	2019-12-31

773 rows × 2 columns

```
In [141... brent3 = brent2
brent3=brent3.drop(columns=["Máxima_B", "Abertura_B", "Mínima_B", "Vol._B"])
brent3I = brent3.sort_values(by='Data')
brent3I=brent3I.drop(columns=["Data"])
y = brent3I['Último_B']
y
```

```
Out[141... data
2010-01-04    80.12
2010-01-05    80.59
2010-01-06    81.89
2010-01-07    81.51
2010-01-08    81.37
...
2019-12-24    67.20
2019-12-26    67.92
2019-12-27    68.16
2019-12-30    68.44
2019-12-31    66.00
Name: Último_B, Length: 2560, dtype: float64
```

```
In [142... y.index
```

```
Out[142... DatetimeIndex(['2010-01-04', '2010-01-05', '2010-01-06', '2010-01-07',
                     '2010-01-08', '2010-01-11', '2010-01-12', '2010-01-13',
                     '2010-01-14', '2010-01-15',
                     ...,
                     '2019-12-17', '2019-12-18', '2019-12-19', '2019-12-20',
                     '2019-12-23', '2019-12-24', '2019-12-26', '2019-12-27',
                     '2019-12-30', '2019-12-31'],
                     dtype='datetime64[ns]', name='data', length=2560, freq=None)
```

```
In [143... y
```

data

```
Out[143...] 2010-01-04    80.12
            2010-01-05    80.59
            2010-01-06    81.89
            2010-01-07    81.51
            2010-01-08    81.37
            ...
            2019-12-24    67.20
            2019-12-26    67.92
            2019-12-27    68.16
            2019-12-30    68.44
            2019-12-31    66.00
            Name: Último_B, Length: 2560, dtype: float64
```


```
In [144...] y=y.resample('d').mean()
```

```
In [145...] y
```

```
Out[145...] data
            2010-01-04    80.12
            2010-01-05    80.59
            2010-01-06    81.89
            2010-01-07    81.51
            2010-01-08    81.37
            ...
            2019-12-27    68.16
            2019-12-28     NaN
            2019-12-29     NaN
            2019-12-30    68.44
            2019-12-31    66.00
            Freq: D, Name: Último_B, Length: 3649, dtype: float64
```

```
In [146...] y_trainSK, y_testSK = temporal_train_test_split(y, test_size=773)
            plot_series(y_trainSK, y_testSK, labels=["y_train", "y_test"])
            print(y_trainSK.shape[0], y_testSK.shape[0])
```

```
2876 773
```



```
In [147...] fh = np.arange(len(y_testSK)) + 1
            fh
```

```
Out[147...] array([ 1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13,
            14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26,
            27, 28, 29, 30, 31, 32, 33, 34, 35, 36, 37, 38, 39,
            40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50, 51, 52,
            53, 54, 55, 56, 57, 58, 59, 60, 61, 62, 63, 64, 65,
            66, 67, 68, 69, 70, 71, 72, 73, 74, 75, 76, 77, 78,
            79, 80, 81, 82, 83, 84, 85, 86, 87, 88, 89, 90, 91,
            92, 93, 94, 95, 96, 97, 98, 99, 100, 101, 102, 103, 104,
            105, 106, 107, 108, 109, 110, 111, 112, 113, 114, 115, 116, 117,
            118, 119, 120, 121, 122, 123, 124, 125, 126, 127, 128, 129, 130,
            131, 132, 133, 134, 135, 136, 137, 138, 139, 140, 141, 142, 143,
            144, 145, 146, 147, 148, 149, 150, 151, 152, 153, 154, 155, 156,
```

```

157, 158, 159, 160, 161, 162, 163, 164, 165, 166, 167, 168, 169,
170, 171, 172, 173, 174, 175, 176, 177, 178, 179, 180, 181, 182,
183, 184, 185, 186, 187, 188, 189, 190, 191, 192, 193, 194, 195,
196, 197, 198, 199, 200, 201, 202, 203, 204, 205, 206, 207, 208,
209, 210, 211, 212, 213, 214, 215, 216, 217, 218, 219, 220, 221,
222, 223, 224, 225, 226, 227, 228, 229, 230, 231, 232, 233, 234,
235, 236, 237, 238, 239, 240, 241, 242, 243, 244, 245, 246, 247,
248, 249, 250, 251, 252, 253, 254, 255, 256, 257, 258, 259, 260,
261, 262, 263, 264, 265, 266, 267, 268, 269, 270, 271, 272, 273,
274, 275, 276, 277, 278, 279, 280, 281, 282, 283, 284, 285, 286,
287, 288, 289, 290, 291, 292, 293, 294, 295, 296, 297, 298, 299,
300, 301, 302, 303, 304, 305, 306, 307, 308, 309, 310, 311, 312,
313, 314, 315, 316, 317, 318, 319, 320, 321, 322, 323, 324, 325,
326, 327, 328, 329, 330, 331, 332, 333, 334, 335, 336, 337, 338,
339, 340, 341, 342, 343, 344, 345, 346, 347, 348, 349, 350, 351,
352, 353, 354, 355, 356, 357, 358, 359, 360, 361, 362, 363, 364,
365, 366, 367, 368, 369, 370, 371, 372, 373, 374, 375, 376, 377,
378, 379, 380, 381, 382, 383, 384, 385, 386, 387, 388, 389, 390,
391, 392, 393, 394, 395, 396, 397, 398, 399, 400, 401, 402, 403,
404, 405, 406, 407, 408, 409, 410, 411, 412, 413, 414, 415, 416,
417, 418, 419, 420, 421, 422, 423, 424, 425, 426, 427, 428, 429,
430, 431, 432, 433, 434, 435, 436, 437, 438, 439, 440, 441, 442,
443, 444, 445, 446, 447, 448, 449, 450, 451, 452, 453, 454, 455,
456, 457, 458, 459, 460, 461, 462, 463, 464, 465, 466, 467, 468,
469, 470, 471, 472, 473, 474, 475, 476, 477, 478, 479, 480, 481,
482, 483, 484, 485, 486, 487, 488, 489, 490, 491, 492, 493, 494,
495, 496, 497, 498, 499, 500, 501, 502, 503, 504, 505, 506, 507,
508, 509, 510, 511, 512, 513, 514, 515, 516, 517, 518, 519, 520,
521, 522, 523, 524, 525, 526, 527, 528, 529, 530, 531, 532, 533,
534, 535, 536, 537, 538, 539, 540, 541, 542, 543, 544, 545, 546,
547, 548, 549, 550, 551, 552, 553, 554, 555, 556, 557, 558, 559,
560, 561, 562, 563, 564, 565, 566, 567, 568, 569, 570, 571, 572,
573, 574, 575, 576, 577, 578, 579, 580, 581, 582, 583, 584, 585,
586, 587, 588, 589, 590, 591, 592, 593, 594, 595, 596, 597, 598,
599, 600, 601, 602, 603, 604, 605, 606, 607, 608, 609, 610, 611,
612, 613, 614, 615, 616, 617, 618, 619, 620, 621, 622, 623, 624,
625, 626, 627, 628, 629, 630, 631, 632, 633, 634, 635, 636, 637,
638, 639, 640, 641, 642, 643, 644, 645, 646, 647, 648, 649, 650,
651, 652, 653, 654, 655, 656, 657, 658, 659, 660, 661, 662, 663,
664, 665, 666, 667, 668, 669, 670, 671, 672, 673, 674, 675, 676,
677, 678, 679, 680, 681, 682, 683, 684, 685, 686, 687, 688, 689,
690, 691, 692, 693, 694, 695, 696, 697, 698, 699, 700, 701, 702,
703, 704, 705, 706, 707, 708, 709, 710, 711, 712, 713, 714, 715,
716, 717, 718, 719, 720, 721, 722, 723, 724, 725, 726, 727, 728,
729, 730, 731, 732, 733, 734, 735, 736, 737, 738, 739, 740, 741,
742, 743, 744, 745, 746, 747, 748, 749, 750, 751, 752, 753, 754,
755, 756, 757, 758, 759, 760, 761, 762, 763, 764, 765, 766, 767,
768, 769, 770, 771, 772, 773])

```

```

In [148... fh = ForecastingHorizon(y_testSK.index, is_relative=False)
           fh

```

```

Out[148... ForecastingHorizon(['2017-11-19', '2017-11-20', '2017-11-21', '2017-11-22',
                                '2017-11-23', '2017-11-24', '2017-11-25', '2017-11-26',
                                '2017-11-27', '2017-11-28',
                                ...,
                                '2019-12-22', '2019-12-23', '2019-12-24', '2019-12-25',
                                '2019-12-26', '2019-12-27', '2019-12-28', '2019-12-29',
                                '2019-12-30', '2019-12-31'],
                                dtype='datetime64[ns]', name='data', length=773, freq='D', is_relative=False)

```

```

In [149... y.isnull().sum()

```


Out[149... 1089

```
In [170... y_mediana = y.rolling(5).mean().shift(-5).round(0)
y.fillna(y_mediana, inplace=True)
```

```
In [171... y.isnull().sum()
```

Out[171... 0

```
In [175... y_train_mediana = y.rolling(5).mean().shift(-5).round(0)
y_trainSK.fillna(y_train_mediana, inplace=True)

y_test_mediana = y.rolling(5).mean().shift(-5).round(0)
y_testSK.fillna(y_test_mediana, inplace=True)
```

```
In [176... y_trainSK.isnull().sum()
```


Out[176... 0

```
In [177... y_testSK.isnull().sum()
```

Out[177... 0


```
In [178... forecaster = NaiveForecaster(strategy="last")
forecaster.fit(y_trainSK)
y_pred = forecaster.predict(fh)
plot_series(y_trainSK, y_testSK, y_pred, labels=["y_train", "y_test", "y_pred"])
smape_loss(y_pred, y_testSK)
```

Out[178... 0.09236973081303312



```
In [179... plot_series(y_testSK, y_pred, labels=["y_test", "y_pred"])
```

Out[179... (<Figure size 1152x288 with 1 Axes>, <AxesSubplot:ylabel='Último_B'>)




```
In [181... print('MAE: ', mean_absolute_error(y_testSK,y_pred))
print('MSE: ', mean_squared_error(y_testSK,y_pred))
print('RMSE: ', np.sqrt(mean_squared_error(y_testSK,y_pred)))
```

```
MAE: 6.2411254851228986
MSE: 66.676482923674
RMSE: 8.165566907672364
```


```
In [182... forecaster = NaiveForecaster(strategy="last", sp=12)
forecaster.fit(y_trainSK)
y_pred = forecaster.predict(fh)
plot_series(y_trainSK, y_testSK, y_pred, labels=["y_train", "y_test", "y_pred"])
smape_loss(y_pred, y_testSK)
```

```
Out[182... 0.0951743349663283
```



```
In [183... plot_series(y_testSK, y_pred, labels=["y_test", "y_pred"])
```


```
Out[183... (<Figure size 1152x288 with 1 Axes>, <AxesSubplot:ylabel='Último_B'>)
```



```
In [184... from sktime.forecasting.ets import AutoETS


forecaster = AutoETS(auto=True, sp=12, n_jobs=-1)
forecaster.fit(y_trainSK)
y_pred = forecaster.predict(fh)
plot_series(y_trainSK, y_testSK, y_pred, labels=["y_train", "y_test", "y_pred"])
smape_loss(y_testSK, y_pred)
```

```
Out[184... 0.09332332551947344
```



```
In [185... plot_series(y_testSK, y_pred, labels=[ "y_test", "y_pred"])
```

```
Out[185... (<Figure size 1152x288 with 1 Axes>, <AxesSubplot:ylabel='Último_B'>)
```




```
In [186... print('MAE: ', mean_absolute_error(y_testSK,y_pred))
print('MSE: ', mean_squared_error(y_testSK,y_pred))
print('RMSE: ', np.sqrt(mean_squared_error(y_testSK,y_pred)))
```

```
MAE:  6.3015513938898815
MSE:  67.97582616714709
RMSE:  8.244745367029056
```


```
In [187... forecaster = ThetaForecaster(sp=12)
forecaster.fit(y_trainSK)
alpha = 0.05 # 95% prediction intervals
y_pred, pred_ints = forecaster.predict(fh, return_pred_int=True, alpha=alpha)
smape_loss(y_testSK, y_pred)
```

```
Out[187... 0.14674560330930167
```

```
In [188... fig, ax = plot_series(y_trainSK, y_testSK, y_pred, labels=["y_train", "y_test", "y_pred"])
ax.fill_between(
    ax.get_lines()[-1].get_xdata(),
    pred_ints["lower"],
    pred_ints["upper"],
    alpha=0.2,
    color=ax.get_lines()[-1].get_c(),
    label=f"{1 - alpha}% prediction intervals",
)
ax.legend();
```



```
In [189... fig, ax = plot_series(y_testSK, y_pred, labels=["y_test", "y_pred"])
ax.fill_between(
    ax.get_lines()[-1].get_xdata(),
    pred_ints["lower"],
    pred_ints["upper"],
    alpha=0.2,
    color=ax.get_lines()[-1].get_c(),
    label=f"{1 - alpha}% intervalo de predição",
)
ax.legend();
```



```
In [190... print('MAE: ', mean_absolute_error(y_testSK,y_pred))
print('MSE: ', mean_squared_error(y_testSK,y_pred))
print('RMSE: ', np.sqrt(mean_squared_error(y_testSK,y_pred)))
```

```
MAE: 9.488035578112644
MSE: 123.48841447144301
RMSE: 11.112534115648105
```

ARIMA

```
In [192... %matplotlib inline
from matplotlib.pylab import rcParams
rcParams['figure.figsize']=15,6
```

```
In [193... from pmdarima.arima import auto_arima
```

```
In [194... z= y_trainI.copy()
z=z.drop(columns=["Data"])
z
```

```
Out[194... Último_B

data
2010-01-04    80.12
```

Último_B

data	
2010-01-05	80.59
2010-01-06	81.89
2010-01-07	81.51
2010-01-08	81.37
...	...
2016-12-23	55.16
2016-12-27	56.09
2016-12-28	56.22
2016-12-29	56.14
2016-12-30	56.82

1787 rows × 1 columns

```
In [195... stepwise_model=auto_arima(z, start_p=1, start_q=1, max_p=6, max_q=6, m=12, start_P=0, s
```

```
ARIMA(0,1,0)(0,0,0)[0] intercept : AIC=6378.379, Time=1.36 sec
ARIMA(0,1,1)(0,0,0)[0] intercept : AIC=6378.085, Time=0.47 sec
ARIMA(0,1,2)(0,0,0)[0] intercept : AIC=6378.694, Time=0.56 sec
ARIMA(0,1,3)(0,0,0)[0] intercept : AIC=6380.694, Time=0.73 sec
ARIMA(0,1,4)(0,0,0)[0] intercept : AIC=6381.979, Time=0.75 sec
ARIMA(0,1,5)(0,0,0)[0] intercept : AIC=6383.962, Time=1.05 sec
ARIMA(1,1,0)(0,0,0)[0] intercept : AIC=6378.218, Time=0.30 sec
ARIMA(1,1,1)(0,0,0)[0] intercept : AIC=6379.239, Time=1.52 sec
ARIMA(1,1,2)(0,0,0)[0] intercept : AIC=6380.695, Time=0.56 sec
ARIMA(1,1,3)(0,0,0)[0] intercept : AIC=6381.425, Time=3.27 sec
ARIMA(1,1,4)(0,0,0)[0] intercept : AIC=6383.988, Time=1.10 sec
ARIMA(2,1,0)(0,0,0)[0] intercept : AIC=6378.652, Time=0.61 sec
ARIMA(2,1,1)(0,0,0)[0] intercept : AIC=6380.642, Time=1.85 sec
ARIMA(2,1,2)(0,0,0)[0] intercept : AIC=6381.539, Time=3.60 sec
ARIMA(2,1,3)(0,0,0)[0] intercept : AIC=inf, Time=5.92 sec
ARIMA(3,1,0)(0,0,0)[0] intercept : AIC=6380.629, Time=0.56 sec
ARIMA(3,1,1)(0,0,0)[0] intercept : AIC=6382.633, Time=0.85 sec
ARIMA(3,1,2)(0,0,0)[0] intercept : AIC=6381.090, Time=4.46 sec
ARIMA(4,1,0)(0,0,0)[0] intercept : AIC=6382.056, Time=0.67 sec
ARIMA(4,1,1)(0,0,0)[0] intercept : AIC=6384.054, Time=0.78 sec
ARIMA(5,1,0)(0,0,0)[0] intercept : AIC=6384.055, Time=0.89 sec
```

```
Best model: ARIMA(0,1,1)(0,0,0)[0] intercept
Total fit time: 31.973 seconds
```

```
In [196... print(stepwise_model.aic())
```

```
6378.084892238259
```

```
In [197... trainarima=z.loc['2010-01-01':'2016-12-31']
testarima=y.loc['2017-01-01':]
```

```
In [198... stepwise_model.fit(trainarima)
```

```
Out[198... ARIMA(order=(0, 1, 1), scoring_args={}, suppress_warnings=True)
```

```
In [199... future_forecastarima=stepwise_model.predict(n_periods=1095)
```

```
In [200... future_forecastarima=pd.DataFrame(future_forecastarima,index=testarima.index, columns=[
```

```
In [201... pd.concat([testarima, future_forecastarima], axis=1).plot()
```

```
Out[201... <AxesSubplot:xlabel='data'>
```



```
In [202... pd.concat([z,testarima, future_forecastarima], axis=1).plot(linewidth=3)
```

```
Out[202... <AxesSubplot:xlabel='data'>
```



```
In [203... print('MAE: ', mean_absolute_error(testarima, future_forecastarima))
print('MSE: ', mean_squared_error(testarima, future_forecastarima))
print('RMSE: ', np.sqrt(mean_squared_error(testarima, future_forecastarima)))
```

```
MAE: 15.283343938135479
MSE: 319.1676593546785
RMSE: 17.86526404379959
```

```
In [ ]:
```